Guia Sencilla para Explicar el Proyecto

Version de charla para publico con poca base tecnica

Proyecto `EMG_Prosthesis_TD3`

26 de marzo de 2026

Resumen

Esta guia sirve para explicar el proyecto de forma sencilla. La idea central es muy simple: se quiso ensenar a una protesis mioelectrica a seguir la apertura de una mano de referencia sin moverse de forma brusca ni gastar accion de mas. El camino no fue lineal. Primero hubo que arreglar el problema y encontrar un benchmark valido; despues hubo que buscar una mejora real sin destruir el tracking. El punto final de la charla es el agente residual `Agent1850`, que mantiene casi el mismo tracking del benchmark `Agent7250` pero con menos esfuerzo y menos saturacion.

Índice

1. La idea general en una frase **2**

2. Diccionario basico **2**

3. Como se puede contar la historia del proyecto **2**

4. Que hacia el benchmark `Agent7250` **3**

5. Por que no se cerro el proyecto con `Agent7250` **3**

6. Experimentos que se probaron despues **3**

7. La idea que si funciono: politica residual **3**

8. Grafica de aprendizaje: como leerla **4**

9. Grafica de test: como leerla **5**

10. Grafica final de comparacion **6**

11. Que fue el barrido de alpha **6**

12. Que significa que el residual haya quedado en ConditionB **7**

13. Resultado final para contar en la charla **7**

14. Fuentes de apoyo **7**

1. La idea general en una frase

El proyecto intenta que una protesis aprenda a moverse de forma continua a partir de senales musculares y de estado, para copiar una referencia parecida al movimiento de una mano humana [1, 2].

2. Diccionario basico

Cuadro 1: Palabras clave explicadas de forma simple

Termino	Explicacion sencilla
EMG	Senal electrica de los musculos. Es una pista de lo que la persona quiere hacer.
Glove	Guante con sensores que da una referencia de movimiento. Aqui se usa como "lo que la protesis deberia seguir".
Protesis	La mano o sistema que queremos controlar.
TD3	Un algoritmo de aprendizaje por refuerzo para acciones continuas [3].
Reward	La nota que recibe el agente. Si sigue bien la referencia y no se mueve de forma brusca, la nota mejora.
Tracking	Que tan bien la protesis sigue a la referencia.
Saturacion	Cuando la accion se pega demasiado al borde maximo o minimo del actuador.
Checkpoint	Una copia guardada del agente en cierto episodio para poder auditarlo o testearlo.
Residual policy	Una politica que no reemplaza a la anterior, sino que le suma una correccion pequena [4, 5, 6].
Alpha residual	El tamano de esa correccion. Si es pequeno, corrige poco; si es grande, corrige mucho.

3. Como se puede contar la historia del proyecto

La historia se puede explicar en cuatro pasos:

1. habia una idea base correcta: usar TD3 para controlar una protesis de forma continua;
2. antes de comparar agentes hubo que arreglar la reward y el simulador;
3. el primer gran benchmark valido fue `Agent7250`;
4. despues se abrio una fase nueva: mejorar ese benchmark sin perder tracking.

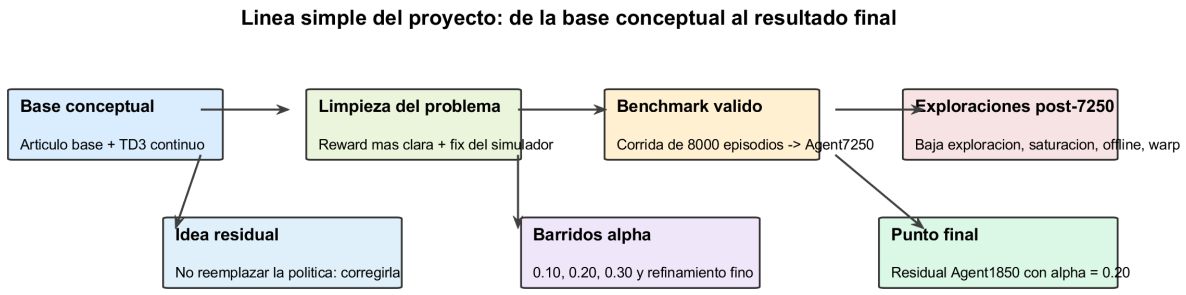

Figura 1: Linea simple del proyecto. Esta figura sirve para contar la historia sin entrar aun en detalles matematicos.

Como explicarla oralmente. Primero se dice que el proyecto no termino en la primera corrida buena. Al principio hubo que limpiar el problema. Luego aparecio `Agent7250` como benchmark serio. Despues se probaron varias ideas nuevas. La unica que realmente mejoro el compromiso global fue la politica residual.

4. Que hacia el benchmark `Agent7250`

El benchmark valido quedo con estas ideas:

- observacion `markov52`;
- reward `trackingMseActionRateReward`;
- TD3 feedforward;
- accion cuantizada para respetar el actuador real.

Esto significa, en lenguaje simple, que el agente ve un estado resumido del sistema y aprende a escoger cuatro acciones continuas. Luego el entorno transforma esas acciones en comandos efectivos compatibles con la protesis.

5. Por que no se cerro el proyecto con `Agent7250`

`Agent7250` seguia bien la referencia, pero aun pagaba bastante en esfuerzo y saturacion. Por eso no bastaba con decir "ya funciona". La pregunta nueva fue:

> *Podemos conservar casi el mismo tracking, pero movernos de forma menos agresiva?*

Ese cambio de pregunta es muy importante, porque explica por que hubo tantas pruebas despues del benchmark.

6. Experimentos que se probaron despues

Cuadro 2: Experimentos posteriores al benchmark y lectura simple

Idea	Por que parecia buena	Que paso al final
Bajar exploracion	Menos ruido podia suavizar una politica ya buena	Suavizo, pero empeoro demasiado el tracking.
Exploracion cerca del umbral	El actuador tenia una discontinuidad real	No mejoro el mejor casi-acierto.
Reward de saturacion	Castigar el borde parecia razonable	La politica se volvio demasiado timida.
Warm-start offline	Darle un prior suave al agente nuevo	Tambien quedo demasiado conservador.
Warp de accion	Alinear mejor accion continua y actuador	La politica se volvio demasiado agresiva.
Residual TD3	Corregir una politica buena en vez de rehacerla	Fue la primera mejora aceptable y defendible.

7. La idea que si funciono: politica residual

La idea residual se puede explicar con esta frase:

> No tiremos la politica buena. Mantengamos a `Agent7250` y aprendamos solo una pequena correccion.

La formula simple es:

$$\text{accion final} = \text{accion base} + \alpha_{\text{res}} \cdot \text{correccion}.$$

Que significa eso en palabras.

- la **accion base** es lo que ya hacia `Agent7250`;
- la **correccion** es un ajuste nuevo que aprende otra rama pequena;
- α_{res} dice cuanto dejamos corregir.

Como explicar el alpha.

- si α es muy pequeno, la correccion casi no alcanza y todo queda demasiado parecido al benchmark;
- si α es muy grande, la correccion manda demasiado y se vuelve facil romper el equilibrio;
- por eso se hicieron barridos de α: para encontrar un punto intermedio.

8. Grafica de aprendizaje: como leerla

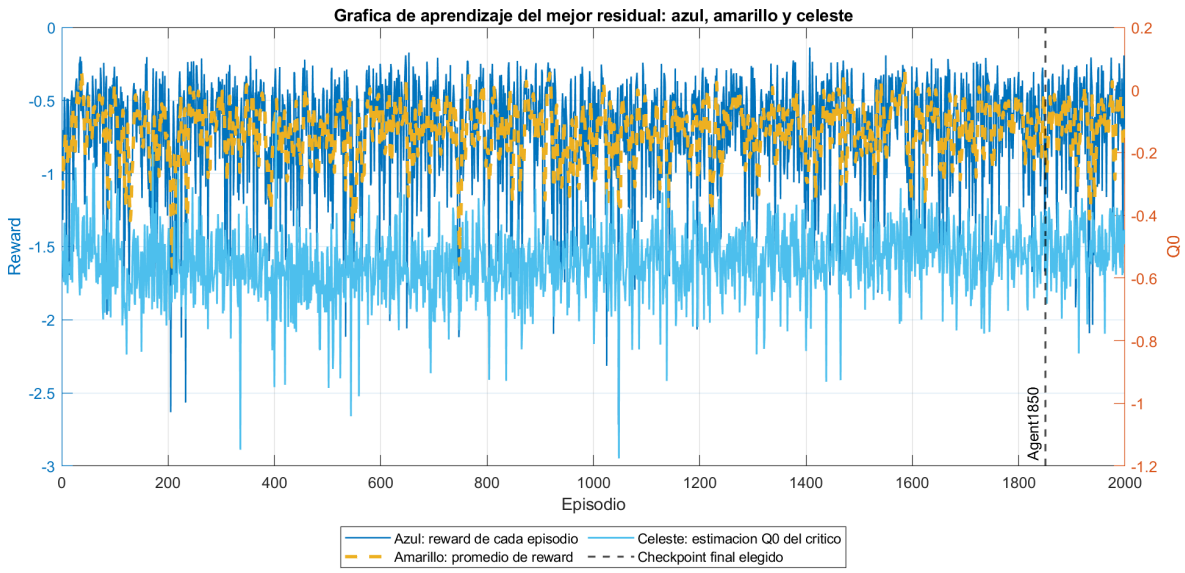

Figura 2: Grafica didactica del entrenamiento residual. Esta es una de las figuras mas utiles para explicar el aprendizaje.

Linea azul. Es la reward de cada episodio. Sube y baja mucho porque cada episodio puede salir un poco distinto. No hay que juzgar el entrenamiento solo por esta linea.

Linea amarilla. Es el promedio de reward. Esta es la linea mas util para explicar la tendencia general. Si sube, el entrenamiento en promedio va mejorando. Si cae de forma sostenida, algo va mal.

Linea celeste. Es el `Q0`, una estimacion interna del critico. Para una charla sencilla basta decir que es "la confianza del modelo sobre el valor esperado de sus decisiones". Si cambia de forma razonable mientras mejora la linea amarilla, el aprendizaje parece coherente. Si se dispara o se hunde sin mejora real, puede haber desajuste.

Linea vertical negra. Marca el checkpoint elegido, `Agent1850`. Aqui es importante explicar algo clave del proyecto: el mejor agente no se eligio por intuicion ni por "verse bonito" en entrenamiento, sino por auditoria y test.

9. Grafica de test: como leerla

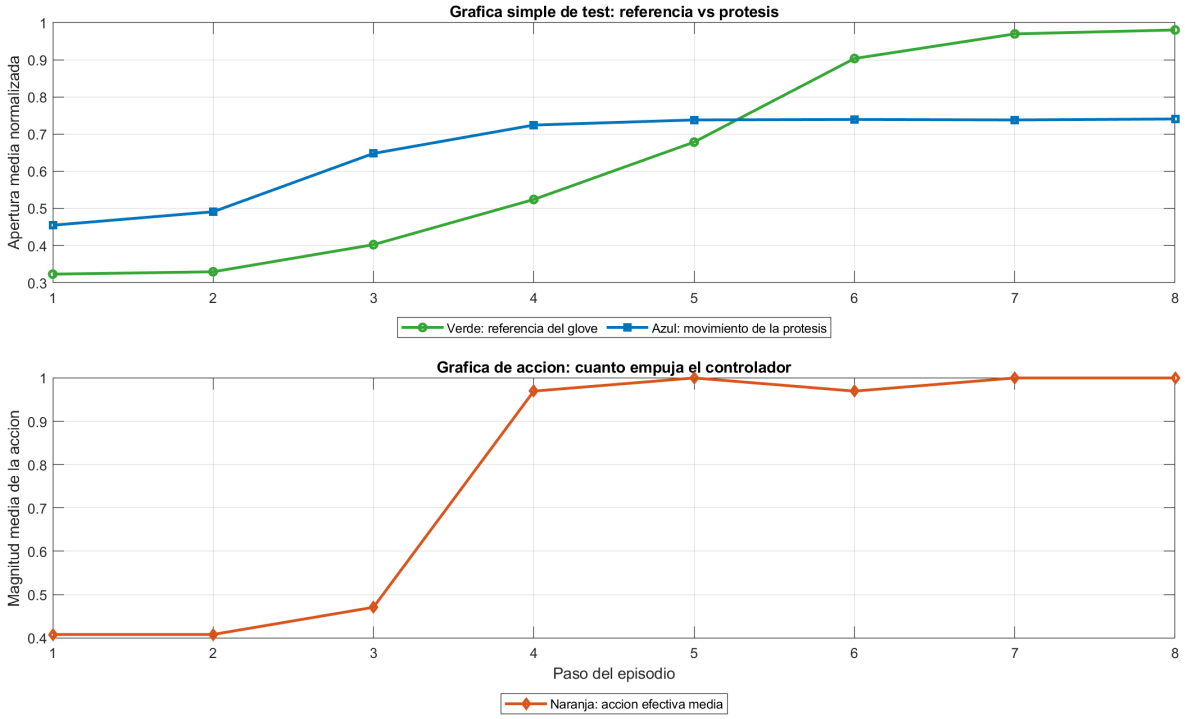

Figura 3: Grafica simple de test. Arriba se ve si la protesis sigue a la referencia. Abajo se ve cuanto empuja el controlador.

Linea verde. Es la referencia del glove. Es el movimiento que la protesis intenta copiar.

Linea azul. Es el movimiento real de la protesis. Si va cerca de la verde, el tracking es bueno. Si se queda muy abajo o se separa mucho, el tracking es malo.

Linea naranja. Es la magnitud de accion. Sirve para ver cuanta "fuerza de control" esta usando el sistema. Si esta siempre muy arriba, la politica es agresiva. Si esta demasiado abajo y la protesis casi no sigue, la politica es timida.

10. Grafica final de comparacion

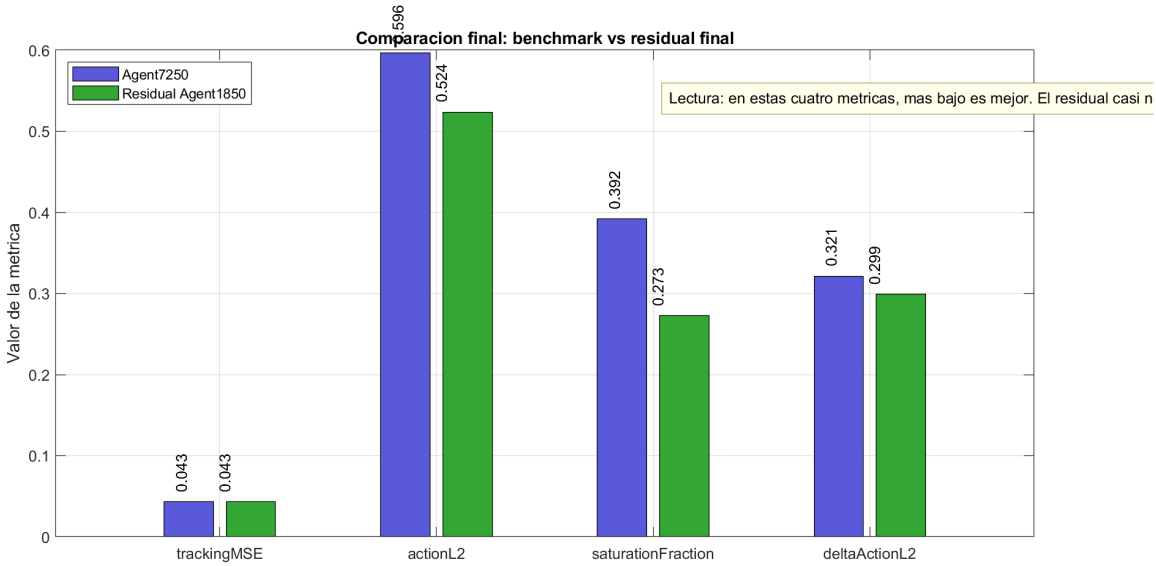

Figura 4: Comparacion final entre `Agent7250` y el residual `Agent1850`.

Como leer esta grafica. Aqui las cuatro metricas se leen igual: mas bajo es mejor.

- **trackingMSE**: error de seguimiento;
- **actionL2**: cuanto esfuerzo total usa la accion;
- **saturationFraction**: cuanto tiempo se pega al borde;
- **deltaActionL2**: que tan bruscos son los cambios.

Que cuenta esta grafica. El residual final empeora un poco el `trackingMSE`, pero mejora de forma clara el esfuerzo, la saturacion y la brusquedad. Esa es justamente la idea de una mejora de compromiso.

11. Que fue el barrido de alpha

Despues del piloto residual se probaron varios valores de α_{res}:

- barrido corto: $0.10, 0.20, 0.30$;
- refinamiento fino: $0.18, 0.20, 0.22, 0.25$.

La conclusion fue sencilla:

- 0.10 corregia poco;
- 0.30 corregia demasiado;
- 0.20 quedo en el mejor punto intermedio;
- el refinamiento fino confirmo que 0.20 seguia siendo la mejor opcion.

12. Que significa que el residual haya quedado en ConditionB

No significa "gana en todo". Significa algo mas realista y mas util:

- no empeora tracking de forma grave;
- baja saturacion de forma clara;
- baja esfuerzo total de forma clara.

En este proyecto eso fue suficiente para tomar al residual `Agent1850` como punto final operativo.

13. Resultado final para contar en la charla

La forma simple de cerrar la charla puede ser esta:

> Primero hubo que limpiar el problema. Luego se encontro un benchmark serio, `Agent7250`. Despues se probaron varias formas de mejorarlo. La que realmente funciono fue no destruir la politica buena, sino corregirla un poco con una politica residual. Asi aparecio `Agent1850`, que mantiene casi el mismo tracking pero con menos agresividad.

14. Fuentes de apoyo

Para esta charla conviene citar solo la idea principal de cada fuente:

- el articulo base del proyecto [1];
- el paper original de TD3 [3];
- la revision sobre control mioelectrico [2];
- la idea de politica residual [4, 5, 6];
- la documentacion de MathWorks para actores continuos y TD3 [7, 8, 9].

Referencias

[1] Jose Gabriel Fuertes Bustos, Carlos Ayala, Lorena Isabel Barona, Marco E. Benalcazar, and Angel Leonardo Valdivieso. Continuous operation of a myoelectric hand prosthesis using the td3 reinforcement learning algorithm. Technical manuscript provided by the user, 2026. Baseline conceptual article used as historical reference for the project.

[2] Ziming Chen, Huasong Min, Dong Wang, Ziwei Xia, Fuchun Sun, and Bin Fang. A review of myoelectric control for prosthetic hand manipulation. *Biomimetics*, 8(3):328, 2023.

[3] Scott Fujimoto, Herke van Hoof, and David Meger. Addressing function approximation error in actor-critic methods. https://arxiv.org/abs/1802.09477, 2018. TD3 original paper.

[4] Tom Silver, Kelsey Allen, Joshua B. Tenenbaum, and Leslie P. Kaelbling. Residual policy learning. https://arxiv.org/abs/1812.06298, 2018. Accessed: 2026-03-26.

[5] Charles Schaff and Matthew R. Walter. Residual policy learning for shared autonomy. https://arxiv.org/abs/2004.05097, 2020. Accessed: 2026-03-26.

[6] Residual Off-Policy RL Project Page. Introducing resfit: Residual fine-tuning with off-policy rl. https://residual-offpolicy-rl.github.io/, 2025. Accessed: 2026-03-26.

[7] MathWorks. rltd3agent. https://www.mathworks.com/help/reinforcement-learning/ref/rl.agent.rltd3agent.html, 2026. Accessed: 2026-03-12.

[8] MathWorks. rltd3agentoptions. https://www.mathworks.com/help/reinforcement-learning/ref/rl.option.rltd3agentoptions.html, 2026. Accessed: 2026-03-12.

[9] MathWorks. rlcontinuousdeterministicactor. https://www.mathworks.com/help/reinforcement-learning/ref/rl.function.rlcontinuousdeterministicactor.html, 2026. Accessed: 2026-03-26.