Proyecto TD3 para Protesis

Mioelectrica

Desde la base conceptual hasta el agente residual final

Cesar Zapata

Laboratorio de Investigacion en Inteligencia y Vision Artificial “Alan Turing”

26 de marzo de 2026

Problema y objetivo

Problema

Queremos que una protesis siga una referencia de mano usando senales EMG y estado mecanico.

Dificultad

No basta con moverse: la politica debe evitar saturacion, esfuerzo excesivo y cambios bruscos.

Objetivo final

- buen tracking
- accion moderada
- menos saturacion
- resultado reproducible

Fuente conceptual: manuscrito base de Fuertes et al.; marco TD3 de Fujimoto et al. (2018).

Linea general del proyecto

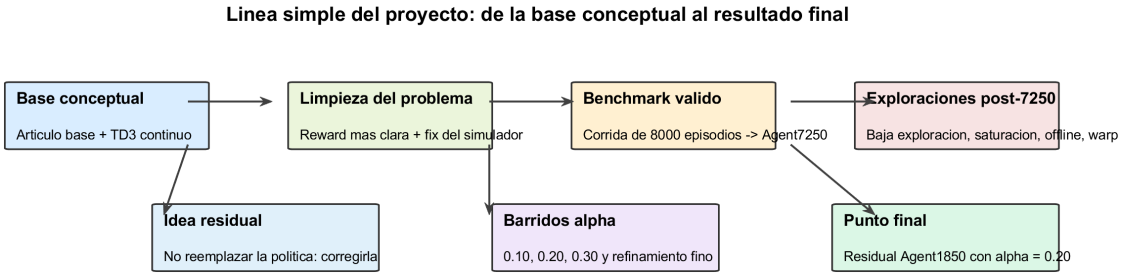

La historia se divide en dos fases: primero obtener un benchmark valido; despues mejorarlo sin romper el tracking.

Que hubo que arreglar antes de comparar agentes

Reward	Accion efectiva	Simulador
Se paso de una reward heredada poco interpretable a una reward centrada en tracking MSE.	Se explicito el remapeo cuantizado a niveles PWM utiles para alinear politica y actuador.	Se detecto un bug importante. Antes del fix, varias corridas no podian usarse como benchmark serio.

Idea clave: primero hubo que volver comparable el problema; solo despues tuvo sentido hablar de "mejor agente".

Reward final: formula y significado de cada termino

$$r_t = -\frac{1}{4}\sum_{i=1}^{4}\left(e_{t,i}^2 + \lambda_a \tilde{a}_{t,i}^2 + \lambda_{\Delta a}(\tilde{a}_{t,i} - \tilde{a}_{t-1,i})^2\right)$$

Que significa cada simbolo

- $e_{t,i}$: error de tracking del motor i
- $\tilde{a}_{t,i}$: accion efectiva aplicada
- λ_a: peso del esfuerzo de accion
- $\lambda_{\Delta a}$: peso del cambio brusco

Como se interpreta

- si el error sube, la reward empeora
- si la accion es muy grande, se castiga
- si cambia demasiado rapido, se castiga
- el objetivo no es solo seguir, sino seguir con control razonable

Lectura simple: tracking como objetivo principal; esfuerzo y suavidad como regularizacion.

Primer benchmark valido: `Agent7250`

Configuracion

- observacion: `markov52`
- reward: MSE + accion + suavidad
- agente: TD3 feedforward
- entrenamiento: 8000 episodios

Metricas del benchmark

- trackingMSE = 0.043045
- trackingMAE = 0.160336
- actionL2 = 0.596444
- saturationFraction = 0.202086

Entrenamiento valido de 8000 episodios

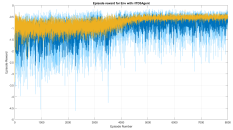

Test visual del benchmark

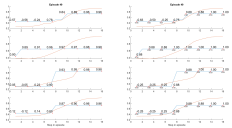

Por que no bastaba con `Agent7250`

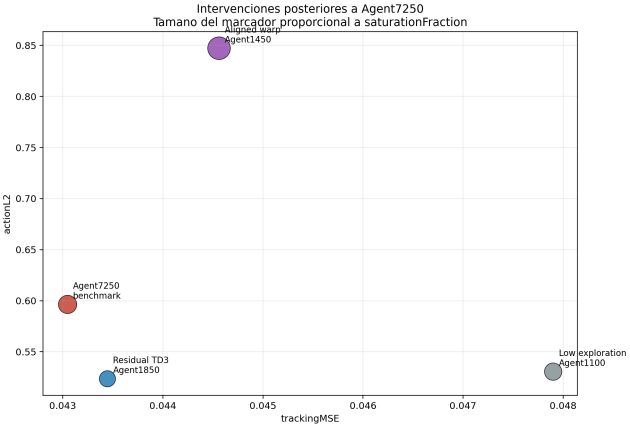

Nueva pregunta

- mantener el tracking
- bajar saturacion
- bajar esfuerzo
- bajar agresividad

Problema observado

Las primeras ideas post-7250 se fueron a dos extremos:

- demasiado timidas
- demasiado agresivas

Experimentos post-7250 en una sola vista

Idea	Por que parecia buena	Resultado
Baja exploracion	Suavizar una politica ya buena	Mejoro suavidad, pero perdio tracking.
Reward de saturacion	Castigar el borde del actuador	Politica demasiado timida.
Warm-start offline	Meter un prior suave	Demasiado conservador.
Warp alineada al actuador	Reducir hueco entre accion y PWM	Politica demasiado agresiva.
Residual TD3	Corregir la politica buena sin reemplazarla	**Primera mejora aceptable**.

La leccion fue clara: no convenia rehacer toda la politica; convenia corregir una politica ya fuerte.

Idea clave: politica residual

$$a_{\text{final}} = \text{clip}\left(a_{\text{base}} + \alpha_{\text{res}}\, a_{\text{corr}}, -1, 1\right)$$

Interpretacion

- a_{base}: accion de `Agent7250`
- a_{corr}: correccion aprendida
- α_{res}: cuanto dejamos corregir

Por que tenia sentido

- `Agent7250` ya hacia buen tracking
- mover toda la politica era riesgoso
- una correccion pequena es mas estable

Lectura del alpha

- muy bajo: corrige poco
- muy alto: rompe el equilibrio
- intermedio: mejor compromiso

Configuracion de la fase residual

Se mantuvo fijo

- `markov52`
- TD3 feedforward
- `trackingMseActionRateReward`
- cuantizacion del actuador
- politica base = `Agent7250`

Se ajusto

- α_{res}
- exploracion residual baja
- auditoria por checkpoints
- test visual de 50 simulaciones

Valor final

$$\alpha_{\text{res}} = 0.20$$

Como leer la grafica de aprendizaje

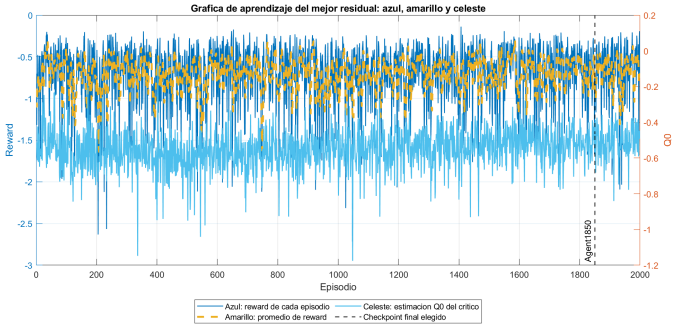

Azul

Reward de cada episodio. Puede oscilar bastante.

Amarillo

Promedio de reward. Sirve para ver la tendencia real.

Celeste

`Q0`. Es una estimacion interna del valor esperado.

Linea negra

Marca `Agent1850`, el checkpoint

Como leer el test del residual

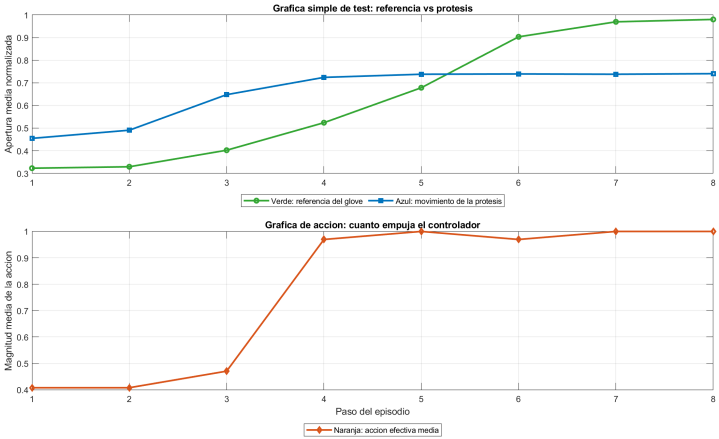

Verde

Referencia del glove.

Azul

Movimiento real de la protesis.

Naranja

Magnitud media de la accion.

Si azul sigue a verde, hay buen tracking.
Si naranja no se dispara, la politica no esta empujando de mas.

Barridos de alpha

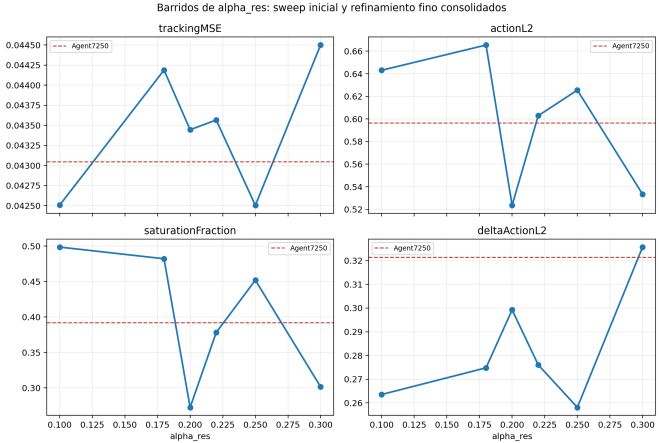

Barrido corto

0.10, 0.20, 0.30

Refinamiento fino

0.18, 0.20, 0.22, 0.25

Conclusion

$\alpha = 0.20$ fue el mejor punto intermedio.
El refinamiento fino lo confirmo.

Comparacion clave: del articulo base al resultado final

Metrica	Articulo base	Post-fix 2000	`Agent7250`	Residual `Agent1850`
trackingMSE	–	0.052805	0.043045	0.043445
trackingMAE	0.1553*	0.179093	0.160336	0.163542
actionL2	–	0.674957	0.596444	0.523597
saturationFraction	–	0.474999	0.392086	0.272637
deltaActionL2	–	0.633264	0.321385	0.299262

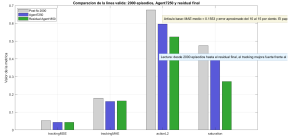

Como leer esta comparacion

* El articulo base reporta MAE medio de simulacion y un error aproximado del 10 al 15 por ciento. No reporta `actionL2`, `saturationFraction` ni `deltaActionL2`, asi que funciona como referencia historica y no como comparacion completa.

Mensaje clave

El residual final mantiene casi el tracking de `Agent7250`, pero reduce esfuerzo y saturacion con una mejora clara.

Lectura final del resultado

Que gano el residual

- baja esfuerzo total
- baja saturacion
- baja brusquedad
- conserva casi el tracking

Que no hizo

No gano por tracking puro.
La mejora fue de **compromiso**, no de un solo numero.

Decision final

`Agent1850` se toma como punto final operativo porque cumple `ConditionB`.

Fuentes clave

- Fuertes Bustos et al., *Continuous Operation of a Myoelectric Hand Prosthesis using the TD3 Reinforcement Learning Algorithm*.
- Fujimoto, van Hoof y Meger (2018), *Addressing Function Approximation Error in Actor-Critic Methods*.
- Chen et al. (2023), *A Review of Myoelectric Control for Prosthetic Hand Manipulation*.
- Silver et al. (2018), *Residual Policy Learning*.
- Schaff y Walter (2020), *Residual Policy Learning for Shared Autonomy*.
- MathWorks, documentacion de `rlTD3Agent`, `rlTD3AgentOptions` y `rlContinuousDeterministicActor`.

Preguntas