Informe Técnico Mejorado de la Intervención Markoviana

TD3 para control continuo de prótesis mioeléctrica en simulación

Proyecto `EMG_Prosthesis_TD3`

19 de marzo de 2026

Resumen

Este informe documenta la intervención más reciente aplicada al proyecto de control continuo de prótesis mioeléctrica con TD3 en MATLAB. El foco ya no está en la corrección básica de la reward o en la autoridad de control, sino en mejorar la consistencia Markoviana del entorno y la calidad de la política aprendida. La intervención nueva introduce un estado ampliado de 52 dimensiones, que incorpora deltas de encoder y la acción efectiva previa, y reemplaza la reward con historia oculta por una reward observable-consistente basada en tracking MSE, magnitud de acción y cambio de acción. El entrenamiento reciente de 2000 episodios muestra el mejor `trackingMSE` medio observado hasta ahora en entrenamiento (0.1055), pero el test del `Agent2000` indica que la mejora en tracking final es todavía marginal. Sin embargo, la nueva formulación sí reduce de forma clara la agresividad del control en evaluación: frente al test de la etapa anterior, el `actionL2` disminuye $\approx 32\,\%$, la fracción de saturación $\approx 57\,\%$ y Δa L2 $\approx 64\,\%$, manteniendo el `trackingMSE` prácticamente igual. La conclusión central es que la intervención Markoviana mejoró la calidad del comportamiento aprendido, pero aún no resuelve el seguimiento fino de la referencia; el siguiente trabajo debe orientarse a selección de checkpoints, auditoría cuantitativa completa y enriquecimiento temporal de la información EMG antes de considerar hardware.

1. Objetivo de este informe

El objetivo de este documento es dejar una versión más clara y profunda del estado actual del proyecto, con énfasis en la **intervención Markoviana reciente**. El documento resume brevemente las etapas previas, explica con detalle el porqué de los cambios nuevos, formaliza matemáticamente el estado y la reward actual, presenta los resultados del entrenamiento de 2000 episodios y del test posterior, y deja una interpretación técnica fundamentada sobre qué mejoró, qué no mejoró y qué debería cambiarse después.

Todo el análisis descrito aquí corresponde exclusivamente a **simulación con datos preregistrados**, con:

- `usePrerecorded = true`,
- `simMotors = true`,
- `connect_glove = false`.

No se ha usado hardware real en ninguna de las corridas documentadas en esta versión del trabajo.

2. Antecedentes breves y útiles

Las etapas previas siguen siendo relevantes, pero aquí solo se resumen sus hallazgos esenciales para contextualizar la intervención nueva. La Tabla 1 sintetiza esa evolución.

Cuadro 1: Resumen breve de las etapas previas

Etapa	**Cambio principal**	**Aporte útil**	**Límite detectado**
Legacy 50	Reward heredada discreta y entorno original	Sirvió como baseline de referencia muy temprana.	Reward incoherente con TD3 continuo, poca trazabilidad y señal difícil de interpretar.
MSE coherente 300	Reward densa basada en tracking MSE normalizado y regularización de acción	Volvió el entrenamiento auditable; alineó la reward con tracking real; corrigió el `step`.	El agente seguía siendo conservador y no explotaba bien la acción en el simulador.
Remapeo 5000	Remapeo explícito a PWM efectivo y compensación de zona muerta	Corrigió una incoherencia física real entre acción continua y actuación aplicada.	Más autoridad de control no produjo una mejora clara de tracking; aparecieron políticas agresivas.
Progreso + suavidad 3000	Reward con progreso temporal y penalización de cambio de acción	Bajó parcialmente la agresividad media en entrenamiento.	La reward dependía de historia no observada por el actor; el test no mejoró tracking y seguía habiendo colapso parcial hacia políticas pobres.

La lectura técnica de estas etapas fue la siguiente:

1. primero era necesario sanear el experimento para que reward, entorno y TD3 fueran interpretables;
2. luego fue necesario hacer que la acción continua del actor tuviera efecto físico real en simulación;
3. finalmente apareció el problema actual: el agente *sí actúa*, pero no usa esa acción con la coordinación suficiente para mejorar tracking.

La corrida larga de 5000 episodios de la etapa de remapeo fue la que dejó más clara esa transición. Su curva se incluye en la Figura 1, porque es el punto en el que el problema dejó de ser "falta de acción efectiva" y pasó a ser "calidad de política".

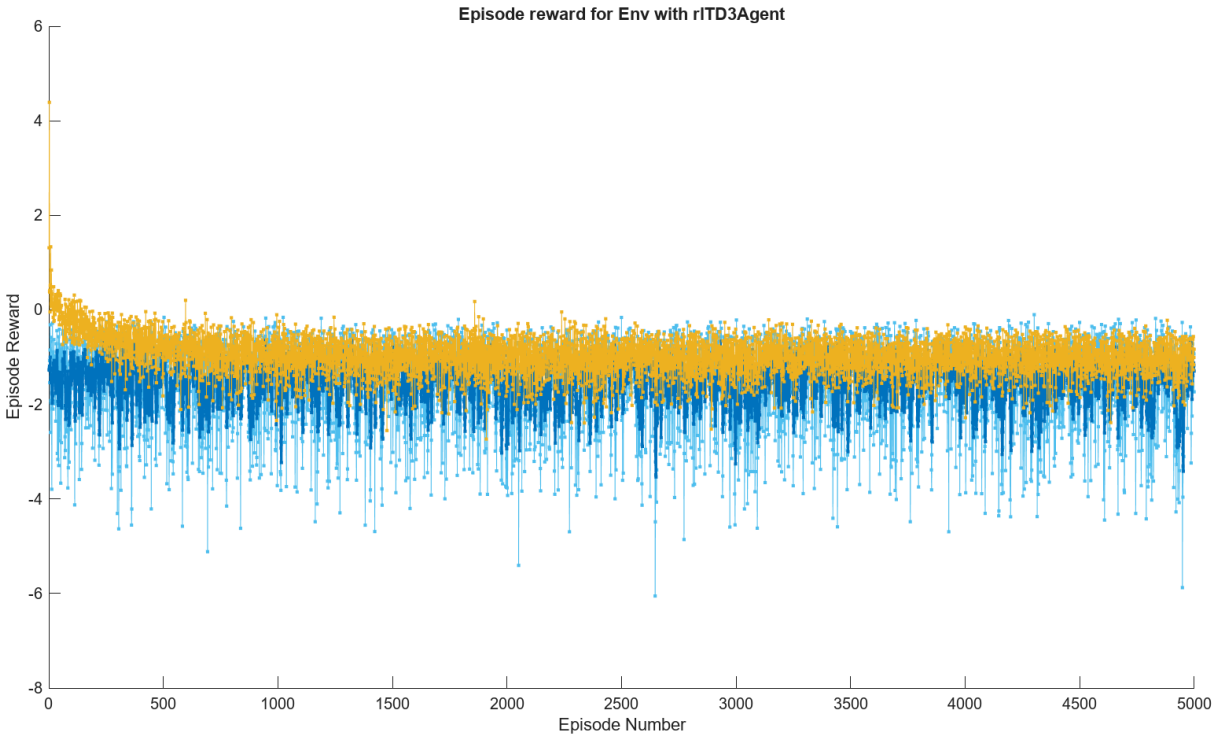

Figura 1: Corrida larga de 5000 episodios con remapeo de acción efectiva. La mejora del tracking se estanca, aunque la acción aplicada aumenta.

En esa corrida, el `trackingMSE` medio quedó en 0.1070, mientras el esfuerzo de control subió de forma clara (`actionL2` medio = 0.3108, $|PWM|$ medio = 125.06). El hallazgo principal fue que **hacer más fuerte la acción no bastaba**.

3. Motivación de la nueva intervención

La intervención actual nace de un diagnóstico puntual del diseño previo. En la etapa *progreso+suavidad*, la reward dependía de:

- la acción previa $\tilde{a}_{t-1}$,
- el `trackingMSE` previo.

Sin embargo, el estado observado por el actor seguía teniendo solo 44 dimensiones:

$$s_t^{(44)} = \begin{bmatrix} \phi(\mathrm{EMG}_t) \\ \mathrm{enc}_t \end{bmatrix},$$

es decir, 40 características EMG y 4 encoders normalizados.

Ese diseño introducía una asimetría importante: la reward usaba historia reciente que el actor no veía de forma explícita. En términos de diseño de entorno, esto no rompía la implementación de MATLAB, pero sí deterioraba la consistencia práctica del problema para una política determinista. Dado que TD3 asume una relación estable entre observación, acción y retorno futuro [Fujimoto et al., 2018, MathWorks, 2026a], mantener historia relevante fuera de la observación podía inducir un comportamiento parcialmente observable sin compensación arquitectónica.

Además, desde el punto de vista de control mioeléctrico, la información temporal no es un detalle secundario. Las revisiones recientes sobre control mioeléctrico subrayan que la dinámica temporal de la señal y el contexto secuencial son determinantes para controlar múltiples grados de libertad de manera estable [Chen et al., 2023]. Del mismo modo, en robótica RL se ha mostrado

que regularizar suavidad ayuda, pero su efecto depende de que la política tenga suficiente contexto para interpretar el cambio de acción [Lee et al., 2024]. En manipulación robótica también existe evidencia de que condicionar la política con acción previa o información temporal mejora el comportamiento secuencial [Kumra et al., 2022].

Por eso la nueva intervención persiguió dos objetivos muy concretos:

1. hacer el problema **más Markoviano** para TD3;
2. simplificar la reward para que toda la historia usada por la penalización estuviera disponible para el agente.

4. Formulación técnica actual

4.1. Acción efectiva retenida desde la etapa anterior

La intervención nueva no deshizo el remapeo de acción efectiva. Ese cambio se mantuvo porque era físicamente correcto y resolvía un problema real del simulador. La acción continua del actor $a_t \in [-1, 1]^4$ sigue convirtiéndose en una acción efectiva $\tilde{a}_t$ mediante cuantización de PWM:

$$u_{t,i}^{\text{eff}} = \begin{cases} 0, & |a_{t,i}| < \epsilon, \\ \operatorname{sign}(a_{t,i})\, q(255|a_{t,i}|)\,, & |a_{t,i}| \geq \epsilon, \end{cases} \tag{1}$$

donde:

- $\epsilon = 0.05$,
- $q(\cdot)$ cuantiza a los niveles $\{64, 96, 128, 160, 192, 224, 255\}$,
- $\tilde{a}_{t,i} = u_{t,i}^{\text{eff}}/255$.

Este remapeo sigue siendo necesario porque el simulador y la conversión encoder–flex no responden de manera lineal a acciones continuas pequeñas. En otras palabras, no es correcto entrenar como si el actuador ejecutara exactamente la salida continua del actor; por eso la reward y el estado usan la acción *efectiva* y no la acción *cruda*.

4.2. Nuevo estado de 52 dimensiones

El nuevo estado se definió como:

$$s_t = \begin{bmatrix} \phi(\text{EMG}_t) \\ \text{enc}_t \\ \Delta\text{enc}_t \\ \tilde{a}_{t-1} \end{bmatrix} \in \mathbb{R}^{52}, \tag{2}$$

donde:

$$\phi(\text{EMG}_t) \in \mathbb{R}^{40}, \tag{3}$$

$$\text{enc}_t \in \mathbb{R}^4, \tag{4}$$

$$\Delta\text{enc}_t = \text{enc}_t - \text{enc}_{t-1} \in [-1, 1]^4, \tag{5}$$

$$\tilde{a}_{t-1} \in [-1, 1]^4. \tag{6}$$

La Tabla 2 resume el significado funcional de cada bloque.

Cuadro 2: Estructura del nuevo estado de 52 dimensiones

Bloque	**Dim.**	**Fuente**	**Propósito**
$\phi(\mathrm{EMG}_t)$	40	`getWmoosFeatures`	Mantener la base de inferencia mioeléctrica original.
enc_t	4	Encoders normalizados	Informar la postura actual de la prótesis.
$\Delta\mathrm{enc}_t$	4	Diferencia de encoders normalizados	Hacer visible el efecto reciente del movimiento y dar contexto dinámico mínimo.
$\tilde{a}_{t-1}$	4	Acción efectiva previa	Hacer observable la historia inmediata relevante para suavidad y coordinación secuencial.

La idea no fue introducir una memoria grande ni una arquitectura recurrente. La intervención buscó un cambio *mínimo y atribuible*: si el problema era la falta de contexto temporal inmediato, entonces bastaba con exponer al actor el *efecto reciente* de la dinámica y la *acción previa realmente aplicada*.

4.3. Reward simplificada y observable-consistente

La reward nueva elimina el término de progreso basado en MSE_{t-1}, precisamente porque ese valor previo no era parte del estado. La formulación actual es:

$$r_t = -\frac{1}{4}\sum_{i=1}^{4}\left(e_{t,i}^2 + \lambda_a \tilde{a}_{t,i}^2 + \lambda_{\Delta a}\left(\tilde{a}_{t,i} - \tilde{a}_{t-1,i}\right)^2\right), \tag{7}$$

con:

$$e_{t,i} = \hat{y}_{t,i} - y_{t,i}^{\star}, \tag{8}$$

donde $\hat{y}_{t,i}$ es la flex estimada de la prótesis y $y_{t,i}^{\star}$ es la flex de referencia proveniente del glove en simulación.

Los pesos usados en esta etapa fueron:

$$\lambda_a = 0.01, \qquad \lambda_{\Delta a} = 0.05. \tag{9}$$

Esta reward conserva tres propiedades importantes:

1. el término principal sigue siendo tracking MSE, que ya había mostrado coherencia con el objetivo del proyecto;
2. la penalización de magnitud de acción se aplica sobre la acción *efectiva* y no sobre la acción idealizada;
3. la penalización de cambio de acción se mantiene, pero ahora el agente sí observa $\tilde{a}_{t-1}$, por lo que la reward deja de depender de historia oculta.

Desde la literatura, esta decisión es coherente con dos líneas: reward shaping denso para manipulación y regularización de suavidad para evitar cambios bruscos [Deng et al., 2025, Lee et al., 2024]. En nuestro caso, la contribución práctica fue **simplificar la reward y trasladar la memoria relevante al estado**.

4.4. Hiperparámetros TD3 mantenidos

La intervención no cambió el algoritmo ni la arquitectura base del agente. Se mantuvo TD3 con la misma MLP, porque el diagnóstico actual no apunta a un fallo de implementación del algoritmo, sino a un problema de representación del estado y de diseño de reward. La Tabla 3 resume la configuración actual.

Cuadro 3: Hiperparámetros TD3 mantenidos en la intervención Markoviana

Parámetro	**Valor**	**Rol técnico**
Unidades ocultas actor/críticos	64	Capacidad moderada, suficiente para esta escala sin aumentar demasiado el costo de entrenamiento.
Actor learning rate	1×10^{-4}	Mantiene actualizaciones conservadoras de la política.
Critic learning rate	1×10^{-3}	Permite que el crítico se adapte más rápido que el actor.
L2 regularization	1×10^{-4}	Ayuda a evitar pesos excesivos y estabiliza la optimización.
Gradient threshold	1	Límite práctico frente a gradientes extremos.
Target smooth factor	0.005	Actualización lenta de redes objetivo, acorde a TD3 [MathWorks, 2026b].
Discount factor γ	0.95	Horizonte razonable para episodios cortos de ≈ 14 pasos.
Mini-batch size	128	Compromiso entre ruido de gradiente y costo de cómputo.
Replay buffer	10^5	Escala adecuada para corridas largas en este problema.
Policy update frequency	2	Implementa *delayed policy updates*, uno de los núcleos de TD3 [Fujimoto et al., 2018].
Target update frequency	2	Sincroniza redes objetivo con la estrategia de actualización diferida.
Exploration std	0.2	Exploración continua moderada durante entrenamiento.
Exploration std min	0.02	Evita que la exploración colapse completamente.
Target policy std	0.2	Suavizado de la política objetivo para reducir errores por sobreestimación [Fujimoto et al., 2018].
Target policy clip	0.5	Limita el ruido objetivo para evitar perturbaciones excesivas.

5. Protocolo experimental de la etapa actual

El piloto nuevo se entrenó desde cero con:

- reward `trackingMseActionRateReward`,
- estado de 52 dimensiones,
- 2000 episodios,
- guardado cada 50 episodios,
- sin plots de entrenamiento en vivo,
- simulación pura con dataset preregistrado.

La corrida quedó almacenada en:

`26-03-19 02 26 41.`

Después del entrenamiento se ejecutó un test visual y cuantitativo del checkpoint final:

`Agent2000.mat`,

con 50 simulaciones y generación de figuras de episodio. El directorio de test correspondiente fue:

`26-03-19 05 25 26.`

Es importante notar que el checkpoint evaluado fue el final nominal de la corrida, no necesariamente el mejor checkpoint global. Esto se hizo para cerrar una primera evaluación end-to-end de la intervención nueva. El mejor promedio de reward de entrenamiento ocurrió alrededor del episodio 1892, de modo que una auditoría fina de checkpoints (`Agent1850`, `Agent1900`, `Agent1950`, `Agent2000`) sigue siendo una tarea pendiente y necesaria.

6. Resultados cuantitativos

6.1. Corrida nueva de 2000 episodios

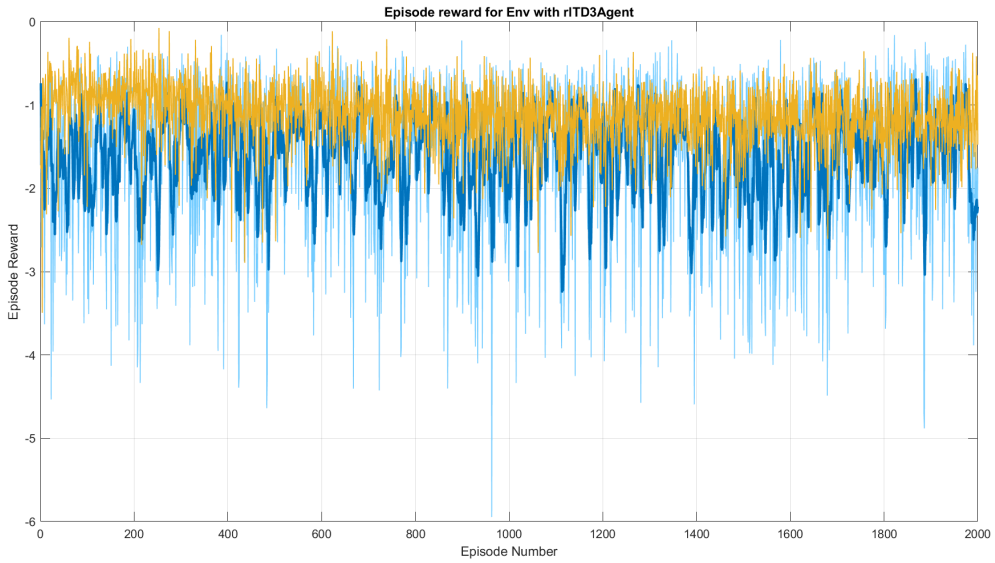

Figura 2: Curva de entrenamiento de la intervención Markoviana de 2000 episodios.

La corrida de 2000 episodios produjo las siguientes métricas de entrenamiento:

- `EpisodeReward` medio: -1.6276,
- `EpisodeReward` final: -1.7531,
- mejor episodio: -0.1563 en el episodio 386,
- `AverageReward` final: -2.2204,
- mejor `AverageReward`: -0.6612 en el episodio 1892,
- `EpisodeQ0` final: -1.4762,

- pasos medios por episodio: 14.54,
- `trackingMSE` medio: 0.10550,
- `trackingMAE` medio: 0.25861,
- `actionL2` medio: 0.33021,
- $|PWM|$ medio: 128.29,
- fracción media de saturación: 0.08478,
- Δa L2 medio: 0.28250.

La comparación más relevante ya no es contra la etapa *legacy*, sino contra las dos etapas inmediatamente anteriores: *remapeo 5000* y *progreso+suavidad 3000*. La Tabla 4 resume esa comparación.

Cuadro 4: Comparación de corridas recientes de entrenamiento

Configuración	**Ep.**	**MSE medio**	**MAE medio**	**Action L2**	**|PWM| medio**	**Frac. sat.**	**Δa L2**	**Reward media**
Remapeo	5000	0.10701	0.26070	0.31081	125.06	0.05299	0.36496	-1.5362
Progreso+suavidad	3000	0.10802	0.26197	0.25428	110.89	0.03969	0.36820	-1.6005
Markoviano + Δa observable	2000	0.10550	0.25861	0.33021	128.29	0.08478	0.28250	-1.6276

La lectura correcta de esta tabla es la siguiente:

- el `trackingMSE` de entrenamiento bajó de 0.10802 a 0.10550 respecto a la etapa *progreso+suavidad*, una mejora aproximada de 2.3 %;
- el Δa L2 medio bajó de 0.36820 a 0.28250, una reducción aproximada de 23.3 %;
- pero el `actionL2` y la fracción de saturación subieron en entrenamiento.

Esto ya anticipa una conclusión importante: **la nueva intervención mejoró coordinación temporal y suavidad relativa entre acciones, pero no eliminó el uso de acción fuerte ni la tendencia a saturar durante entrenamiento**. También es importante aclarar que los valores de reward entre configuraciones distintas no son estrictamente comparables, porque la reward cambió entre etapas; por eso las métricas prioritarias de comparación son `trackingMSE`, `trackingMAE`, `actionL2`, saturación y Δa L2.

6.2. Test del `Agent2000`

El test final del checkpoint `Agent2000` produjo:

- `trackingMSE` medio: 0.10982,
- `trackingMAE` medio: 0.26389,
- `actionL2` medio: 0.28626,
- $|PWM|$ medio: 118.55,
- fracción media de saturación: 0.05786,
- Δa L2 medio: 0.18819,

- reward media de test: -1.6890,
- pasos medios por episodio: 14.50.

La comparación más justa del test nuevo es contra el test de la etapa inmediatamente anterior, es decir, el test de `Agent3000` del experimento *progreso+suavidad*. La Tabla 5 resume esa comparación.

Cuadro 5: Comparación de tests: etapa previa vs etapa Markoviana

Checkpoint testeado	**MSE medio**	**MAE medio**	**Action L2**	**|PWM| medio**	**Frac. sat.**	**Δa L2**
Progreso+suavidad `Agent3000`	0.10982	0.26389	0.42107	147.72	0.13485	0.52202
Markoviano `Agent2000`	0.10982	0.26389	0.28626	118.55	0.05786	0.18819

Esta tabla es probablemente el resultado más importante de toda la intervención nueva. La interpretación es muy clara:

- el `trackingMSE` de test no mejoró de forma apreciable;
- pero el `actionL2` cayó aproximadamente un 32 %;
- $|PWM|$ medio cayó aproximadamente un 19.7 %;
- la fracción de saturación cayó aproximadamente un 57.1 %;
- Δa L2 cayó aproximadamente un 63.9 %.

Es decir: la nueva formulación **no consiguió un mejor tracking final**, pero **sí produjo una política mucho menos agresiva y mucho más suave en evaluación**. Ese resultado es relevante porque corrige justamente uno de los defectos dominantes de la etapa anterior: una política con tracking parecido, pero demasiado costosa y saturada.

6.3. Lectura visual del test

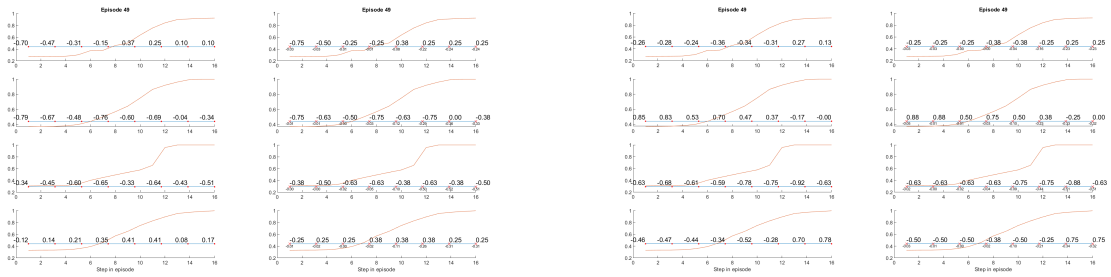

(a) Etapa progreso+suavidad, `Agent3000` (b) Etapa Markoviana, `Agent2000`

Figura 3: Comparación visual del episodio 49 en test. La salida azul sigue lejos de la referencia naranja en ambos casos, pero la política nueva muestra acciones menos extremas y menor saturación visible.

La Figura 3 confirma visualmente lo que ya mostraban las métricas:

- la prótesis sigue sin seguir de forma satisfactoria la trayectoria naranja de referencia;
- por tanto, el problema de tracking persiste;

- sin embargo, la política nueva no está colapsando al mismo nivel de control agresivo que la etapa previa.

En el episodio 49 del test Markoviano, las acciones efectivas se observan más moduladas por canal. Todavía aparecen signos mixtos y tramos de acción relativamente grandes, pero el patrón es menos cercano a un *bang-bang* saturado sostenido. La lectura cualitativa coincide con la cuantitativa: **se mejoró calidad de control, no tracking**.

7. Interpretación técnica

La conclusión técnica más importante de esta etapa es que la intervención nueva **sí resolvió un problema de diseño del experimento**. La reward ya no depende de historia oculta y el actor ya observa la información temporal mínima relevante. Eso hace al sistema más coherente desde el punto de vista de RL y más defendible desde el punto de vista metodológico.

Sin embargo, el resultado también deja claro que el cuello de botella actual cambió de naturaleza:

1. ya no es la falta de acción efectiva;
2. ya no es una reward mal formulada en lo básico;
3. ahora el problema dominante es la **capacidad de la política para traducir EMG instantáneo en coordinación multi-canal fina**.

La evidencia concreta que sostiene esa interpretación es:

- el `trackingMSE` de test quedó prácticamente igual entre la etapa previa y la actual;
- la nueva etapa sí redujo fuertemente saturación, PWM medio y cambio de acción;
- por tanto, el nuevo diseño no empeoró el tracking, pero tampoco consiguió extraer mejor información de la EMG para seguir la referencia.

Desde un punto de vista experimental, eso es un hallazgo valioso. No es un fracaso del cambio: es una delimitación mucho más clara del problema real. El proyecto pasó de un escenario donde el agente estaba sesgado por reward y por actuación no física a un escenario donde la política ya es más suave y coherente, pero la representación disponible sigue siendo insuficiente para tracking fino.

8. Veredicto actual

El veredicto de esta etapa es el siguiente:

- **Sí conviene mantener** el estado ampliado de 52 dimensiones.
- **Sí conviene mantener** la reward simplificada sin término de progreso oculto.
- **Sí conviene mantener** el remapeo a acción efectiva.
- **No conviene todavía** pasar a hardware.
- **No conviene** interpretar este resultado como un problema puramente de "más episodios".

La etapa Markoviana dejó una mejora cualitativa real en la política: menor saturación, menor esfuerzo y mucha menor variación entre acciones. Eso es importante. Pero el resultado también deja una conclusión inequívoca: **todavía no existe una mejora suficiente de tracking para considerar la tarea resuelta**.

9. Trabajo futuro recomendado

Con base en estas evidencias, el siguiente trabajo recomendado es:

1. **Auditoría de checkpoints de la corrida Markoviana.**
   El mejor `AverageReward` ocurrió cerca del episodio 1892. La evaluación del `Agent2000` fue necesaria para cerrar la corrida, pero lo correcto ahora es auditar checkpoints cercanos (`Agent1800`, `Agent1850`, `Agent1900`, `Agent1950`, `Agent2000`) antes de decidir si esta intervención ya dio su mejor política.

2. **Aumentar contexto temporal EMG antes de cambiar algoritmo.**
   La nueva intervención solo añadió memoria mínima de encoders y acción previa. El siguiente cambio de menor riesgo no es SAC ni LSTM directo, sino enriquecer el contexto temporal de entrada conservando TD3. Eso podría hacerse con apilado corto de ventanas EMG o con features temporales adicionales, porque la literatura de control mioeléctrico enfatiza precisamente la relevancia de la estructura temporal [Chen et al., 2023].

3. **Mantener la comparación en simulación pura.**
   Antes de considerar hardware, la siguiente iteración debe demostrar o bien una reducción visible de `trackingMSE`, o bien una mejora equivalente en tracking sin perder la suavidad conseguida ahora.

4. **Mantener como rama futura la acción híbrida.**
   Dado que el actuador real aplica niveles cuantizados y no una acción verdaderamente continua, una futura línea de investigación podría explorar representaciones híbridas de acción, como las propuestas en HyAR [Li et al., 2021]. Esa idea tiene fundamento, pero todavía no es el cambio de menor riesgo en esta etapa.

10. Conclusión

La intervención Markoviana fue **correcta y necesaria**. Mejoró la consistencia del problema para TD3, eliminó historia oculta de la reward y produjo una política de evaluación notablemente más suave. El resultado cuantitativo más importante es que esa mejora de suavidad no vino acompañada de una penalización fuerte en tracking; el `trackingMSE` de test quedó esencialmente igual mientras el costo de control cayó de forma marcada.

No obstante, la meta del proyecto sigue siendo seguimiento satisfactorio de la intención motora, no solo suavidad. Por eso el balance final de esta etapa es mixto: **avance metodológico claro, mejora de calidad de control clara, mejora de tracking final todavía insuficiente**. Esa es precisamente la información que se necesitaba para orientar la siguiente iteración con criterio técnico y sin pasar prematuramente a hardware.

Referencias

Ziming Chen, Huasong Min, Dong Wang, Ziwei Xia, Fuchun Sun, and Bin Fang. A review of myoelectric control for prosthetic hand manipulation. *Biomimetics*, 8(3):328, 2023. doi: 10.3390/biomimetics8030328. URL https://doi.org/10.3390/biomimetics8030328.

Zelin Deng, Yunlong Dong, and Xing Liu. Reward shaping in reinforcement learning for robotic hand manipulation. *Neurocomputing*, 638:130204, 2025. doi: 10.1016/j.neucom.2025.130204. URL https://doi.org/10.1016/j.neucom.2025.130204.

Scott Fujimoto, Herke van Hoof, and David Meger. Addressing function approximation error in actor-critic methods. https://arxiv.org/abs/1802.09477, 2018. TD3 original paper.

Sulabh Kumra, Shirin Joshi, and Ferat Sahin. Learning multi-step robotic manipulation policies from visual observation of scene and q-value predictions of previous action. In *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, 2022. URL https://arxiv.org/abs/2202.11280. arXiv:2202.11280.

I Lee, Hoang-Giang Cao, Cong-Tinh Dao, Yu-Cheng Chen, and I-Chen Wu. Gradient-based regularization for action smoothness in robotic control with reinforcement learning. In *Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 603–610, 2024. URL https://arxiv.org/abs/2407.04315.

B. Li, H. Tang, Y. Zheng, J. Hao, P. Li, Z. Wang, Z. Meng, and L. Wang. Hyar: Addressing discrete-continuous action reinforcement learning via hybrid action representation. https://arxiv.org/abs/2109.05490, 2021. arXiv:2109.05490.

MathWorks. rltd3agent. https://www.mathworks.com/help/reinforcement-learning/ref/rl.agent.rltd3agent.html, 2026a. Accessed: 2026-03-12.

MathWorks. rltd3agentoptions. https://www.mathworks.com/help/reinforcement-learning/ref/rl.option.rltd3agentoptions.html, 2026b. Accessed: 2026-03-12.