

Reporte integral de la fase stop-band residual

Proyecto TD3 para prótesis mioeléctrica

César Zapata

Research Laboratory in Artificial Intelligence and Computer Vision “Alan Turing”

5 de abril de 2026

Propósito de este documento

Este documento ordena la fase stop-band residual siguiendo la misma línea de los reportes previos del proyecto. Primero fija cuál era la línea vigente antes de la intervención, luego explica por qué fue necesario abrir esta fase y finalmente resume qué se aplicó y qué resultado dejó.

Línea vigente antes de la intervención stop-band


La fase stop-band **no** arrancó desde cero. Antes de abrirla, el proyecto ya tenía una línea técnica bien definida:

- **benchmark oficial estable:** `Agent7250`;
- **mejor residual reproducible:** `seed 22`, aceptada bajo `ConditionA`;
- **mejor residual single-run histórico:** `Agent1850`, aceptado bajo `ConditionB`.


Ese estado se consolidó en la propia secuencia de reportes del proyecto: primero se cerró una base estable sobre `Agent7250`, después se abrió la línea residual y finalmente se verificó qué parte de esa mejora se sostenía entre seeds. Por eso la fase stop-band parte de una línea ya madura: no entra a resolver tracking desde cero, sino a decidir dónde conviene detener una trayectoria residual que ya mostraba señales buenas, pero todavía no estaba bien cerrada como regla operativa. Esta lectura es consistente con el uso de TD3 como base de control continuo y con la idea de aprendizaje residual sobre una política ya fuerte, especialmente en tareas donde no basta con seguir la referencia, sino que también importa la agresividad del control y la calidad operativa de la acción [1–3, 6].

Cuadro 1: Referencias activas del proyecto antes de stop-band

Rol	Candidato	Lectura técnica
Benchmark oficial	<code>Agent7250</code>	Política base estable del proyecto; punto fijo para todas las comparaciones posteriores.
Residual reproducible	<code>seed 22</code>	Mejor evidencia entre seeds; referencia operativa de reproducibilidad antes de stop-band.
Residual single-run	<code>Agent1850</code>	Mejor compromiso histórico esfuerzo–saturación en una sola corrida; muy fuerte como referencia cualitativa, pero no suficiente por sí solo como línea reproducible.



(a) Agent7250



(b) Agent1850

Figura 1: Línea vigente antes de stop-band. A la izquierda, el benchmark oficial ya resolvía bien el tracking. A la derecha, la mejor residual single-run mostraba que sí existía margen para bajar esfuerzo y saturación sin destruir el seguimiento.

Por qué fue necesario abrir una fase stop-band

El siguiente paso natural habría sido seguir entrenando más tiempo. Sin embargo, esa hipótesis ya fue puesta a prueba con dos corridas largas de 50,000 episodios: una sobre la base y otra sobre la línea residual. El hallazgo fue consistente en ambos casos: aparecieron checkpoints internamente prometedores dentro de la trayectoria, pero el mejor checkpoint auditado no se sostuvo como nuevo líder al repetir el test final independiente.

En otras palabras, las corridas largas cambiaron la pregunta del proyecto. La pregunta dejó de ser “*si entrenar más ayuda*” y pasó a ser “*en qué zona de la trayectoria conviene detenerse antes de la deriva tardía*”.

En este proyecto, **stop-band** no se refiere a un filtro en frecuencia sobre la señal EMG. Se refiere a una **banda de parada sobre el eje de entrenamiento**: una ventana de episodios en la que conviene buscar y fijar el checkpoint final antes de que la trayectoria empiece a degradarse.

La consecuencia práctica fue inmediata: en esta fase el criterio se desplazó deliberadamente desde “seguir entrenando” hacia “auditar toda la trayectoria y seleccionar la ventana operativamente más sana”. La pregunta ya no era si hacía falta empujar más episodios, sino en qué zona concreta de la trayectoria aparecía el mejor compromiso antes de que el residual empezara a degradarse. Esta decisión también es coherente con observaciones conocidas de deep RL: el entrenamiento prolongado no necesariamente mejora de forma monótona, y en control robótico la suavidad de acción es parte real de la calidad del comportamiento final [4, 5].




Figura 2: Razón inmediata para abrir stop-band. Tanto la extensión larga de la base como la extensión larga residual mostraron que “más episodios” no garantizaba un mejor candidato final frente a Agent7250.

Qué se aplicó exactamente

La intervención stop-band no cambió el benchmark ni cambió la arquitectura general del proyecto. Lo que hizo fue **cambiar la forma de buscar y seleccionar el residual**, manteniendo congelada la base Agent7250 y volviendo más estricta la auditoría temporal.

1. Política residual con base congelada

La política residual activa se mantuvo bajo la forma:

$$a(s) = \text{clip}\left(a_{\text{base}}(s) + \alpha_{\text{res}} a_{\text{res}}(s, a_{\text{base}}), -1, 1\right), \quad (1)$$

donde a_{base} es la acción del benchmark congelado, a_{res} es la corrección aprendible y $\alpha_{\text{res}} = 0.20$ controla cuánto puede apartarse la política final respecto a la base. En términos del proyecto, esto significa que la fase stop-band no cambió la lógica residual ya validada; solo cambió la forma de explotar su trayectoria. La estructura mantiene la base TD3 y la corrección residual acotada como elementos centrales del control [3, 6].

2. Densificación de checkpoints y auditoría de trayectoria completa

En vez de confiar en el último checkpoint o en el **AverageReward** final, la fase stop-band aumentó la densidad de guardado y auditó toda la trayectoria:

- en *discovery*, guardado cada 250 episodios;
- en *confirmation*, guardado cada 100 episodios;
- auditoría en dos fases: 20 simulaciones rápidas para barrer la trayectoria y 50 simulaciones completas para reordenar los mejores candidatos;
- re-test final independiente del checkpoint seleccionado.

3. Regla explícita para derivar la stop-band

Si $\mathcal{E}_{\text{acc}}$ es el conjunto de episodios ganadores de las seeds aceptadas, la propuesta de parada se construyó como:

$$e^* = \text{round}_{250}(\text{median}(\mathcal{E}_{\text{acc}})), \quad (2)$$

y la ventana asociada como

$$W(e^*) = [e^* - 250, e^* + 250]. \quad (3)$$

Cuando *discovery* tenía menos de tres seeds aceptadas, la mediana se mantuvo deliberadamente conservadora y se recortó al rango $[1750, 3000]$ para no dejar que una sola seed tardía arrastrara toda la fase. Esa fue precisamente la situación observada en *discovery*.

4. Regla de selección dentro de la ventana

En *confirmation* no se eligió simplemente el mejor checkpoint global de la tabla. La regla aplicada fue:

1. priorizar el **checkpoint aceptado más temprano** dentro de la ventana $W(e^*)$;
2. si no existía un aceptado dentro de la ventana, mantener el mejor checkpoint interno de esa banda;
3. solo permitir una promoción fuera de la ventana si mejoraba tracking **sin** empeorar **actionL2** ni **saturationFraction**.

Con esto, la stop-band se convirtió en una regla de selección *conservadora*: la fase prefería un checkpoint ligeramente más temprano y estable antes que una cola tardía más riesgosa.

Cuadro 2: Intervención metodológica aplicada en la fase stop-band

Elemento	Regla aplicada
Base de partida	Agent7250 congelado como benchmark y base residual.
Política aprendida	Residual TD3 con $\alpha_{\text{res}} = 0.20$ y 32 unidades ocultas residuales.
Guardado de checkpoints	Denso: cada 250 episodios en <i>discovery</i> y cada 100 en <i>confirmation</i> .
Auditoría	Barrido rápido (20 simulaciones), fase completa (50 simulaciones) y re-test final independiente.
Derivación de banda	Mediana de episodios aceptados, redondeada a 250, con recorte conservador si la evidencia era escasa.
Selección final	Checkpoint aceptado más temprano dentro de la ventana; solo se sale de la banda si el candidato externo no empeora esfuerzo ni saturación.
Promoción de línea	Requiere simultáneamente seeds aceptadas, mejora agregada frente al benchmark y reducción media de actionL2 y saturationFraction .

Discovery: búsqueda inicial de la banda

Configuración

Cuadro 3: Configuración de discovery

Elemento	Valor
Base congelada	Agent7250
Seeds	[11 22 33 44 55]
Episodios por seed	10,000
Guardado	cada 250 episodios
Auditoría	20 simulaciones rápidas, 50 completas, topK = 5
Selección	auditoría completa + re-test final independiente

Resultado agregado

Cuadro 4: Resumen agregado de discovery

Métrica	Valor
Seeds aceptadas	1/5
ConditionA	1
ConditionB	0
Rejected	4
trackingMSE medio $\pm$ std	0.042706 ± 0.000190
trackingMAE medio $\pm$ std	0.160010 ± 0.000368
actionL2 medio $\pm$ std	0.611654 ± 0.014540
saturationFraction media $\pm$ std	0.404822 ± 0.040419
deltaActionL2 medio $\pm$ std	0.367862 ± 0.014986
Estado agregado vs benchmark	Rejected
stop-band propuesta	episodio 3000
Ventana propuesta	[2750, 3250]




Figura 3: Vista general de entrenamiento por seed durante discovery. La dispersión entre seeds confirma que discovery debía funcionar como fase de hipótesis, no de promoción.




Figura 4: Episodios ganadores por seed y distribución final de estados en discovery. La banda propuesta nace de una evidencia aún escasa y por eso se mantiene conservadora.

Lectura

Discovery **no estabilizó la línea por sí solo**. Solo una seed quedó aceptada y el promedio agregado terminó en **Rejected**. Esto es importante porque evita una lectura triunfalista equivocada: la fase inicial no “demostró” una ventana, solo generó una hipótesis de trabajo.

Sin embargo, discovery sí entregó tres señales útiles:

- mostró que la mejora residual no estaba distribuida uniformemente a lo largo de toda la trayectoria;
- mostró que el mejor compromiso no aparecía necesariamente al final de la corrida;
- produjo una zona candidata concreta para someter a validación con seeds nuevas.

En términos de regla, discovery usó una mediana escasa y recortada. Eso es exactamente lo que debía pasar: con una sola seed aceptada, la fase no podía permitirse reaccionar como si ya hubiera evidencia reproducible.

Confirmation: validación de la banda

Configuración

Cuadro 5: Configuración de confirmation

Elemento	Valor
Base congelada	Agent7250
Seeds	[66 77 88 99 111]
stop-band de entrada	episodio 3000 desde discovery
Ventana de trabajo	[2750, 3250] como referencia de entrada, con selección final re-evaluada por auditoría y re-test
Episodios por seed	3500
Guardado	cada 100 episodios
Auditoría	20 simulaciones rápidas, 50 completas, $\text{topK} = 5$
Selección final	checkpoint re-testeado; dentro de la ventana se prioriza el más temprano aceptado

Resultado agregado

Cuadro 6: Resumen agregado de confirmation

Métrica	Valor
Seeds aceptadas	3/5
ConditionA	2
ConditionB	1
Rejected	2
trackingMSE medio $\pm$ std	0.042674 ± 0.000490
trackingMAE medio $\pm$ std	0.159880 ± 0.000776
actionL2 medio $\pm$ std	0.588257 ± 0.037177
saturationFraction media $\pm$ std	0.355790 ± 0.080166
deltaActionL2 medio $\pm$ std	0.368386 ± 0.021190
Estado agregado vs benchmark	ConditionA
stop-band confirmada	episodio 2000
Ventana confirmada	[1750, 2250]
Promoción de línea activa	Sí




Figura 5: Vista general de entrenamiento por seed durante confirmation. La concentración de buenos candidatos aparece más temprano que la banda propuesta en discovery, lo cual refina la regla operativa.

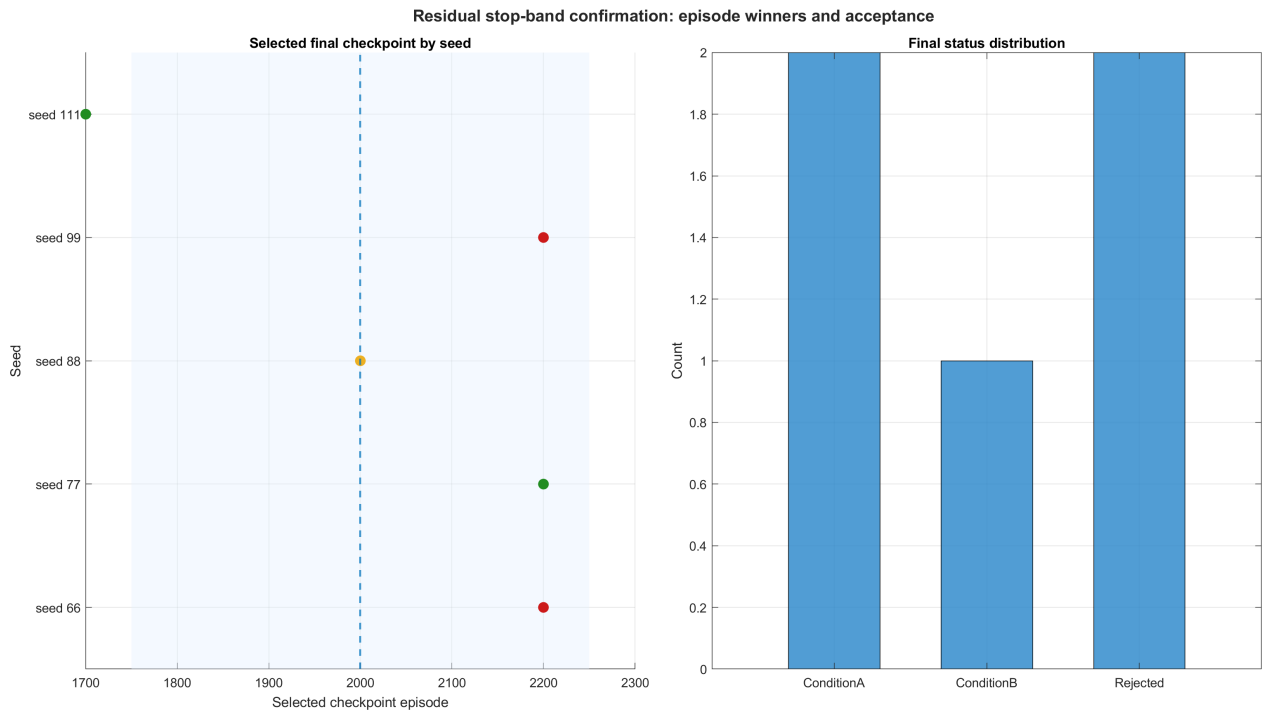


Figura 6: Episodios ganadores por seed y distribución final de estados en confirmation. La mediana de las seeds aceptadas empuja la banda hacia 2000 episodios.

Detalle por seed

Cuadro 7: Checkpoint final seleccionado por seed en confirmation

Seed	Episodio	trackingMSE	actionL2	saturation	deltaActionL2	Estado
66	2200	0.043016	0.626795	0.439649	0.389861	Rejected
77	2200	0.042057	0.553707	0.276106	0.346460	ConditionA
88	2000	0.043291	0.545418	0.268202	0.353852	ConditionB
99	2200	0.042400	0.619077	0.421728	0.392167	Rejected
111	1700	0.042606	0.596287	0.373263	0.359592	ConditionA

Lectura

Aquí apareció la señal fuerte de la fase. A diferencia de discovery:

- 3/5 seeds quedaron aceptadas;
- la media agregada pasó a **ConditionA**;
- la banda confirmada se desplazó hacia una zona **más temprana**, entre 1700 y 2200 episodios;
- la mediana de las seeds aceptadas produjo de forma natural una stop-band de 2000 episodios.

Esto significa que la hipótesis inicial se corrigió a sí misma. Discovery propuso “*mira por aquí*”; confirmation respondió “*la zona buena sí existe, pero está antes de lo que parecía*”.

Comparación contra referencias activas




Figura 7: Comparación del resultado de confirmation contra Agent7250, seed 22 y Agent1850.

Cuadro 8: Comparación final de referencias y campaña confirmada

Candidato	trackingMSE	trackingMAE	actionL2	saturation	deltaActionL2	Estado
Agent7250	0.043045	0.160336	0.596444	0.392086	0.321385	Referencia
Seed22	0.043045	0.160786	0.582152	0.337475	0.327141	ConditionA
Agent1850	0.043445	0.163542	0.523597	0.272637	0.299262	ConditionB
MediaCampana	0.042674	0.159880	0.588257	0.355790	0.368386	ConditionA
MejorSeed	0.042057	0.158791	0.553707	0.276106	0.346460	ConditionA

Interpretación comparativa

La fase confirmada deja una lectura bastante limpia:

- frente a **Agent7250**, la media confirmada mejora tracking y reduce tanto **actionL2** como **saturationFraction**;
- frente a **seed 22**, la campaña confirmada mejora tracking y mantiene una media aceptada, aunque **seed 22** sigue siendo una referencia reproducible muy fuerte;
- frente a **Agent1850**, la stop-band confirmada no borra su valor histórico: **Agent1850** sigue siendo un residual single-run sobresaliente en reducción de esfuerzo y saturación, pero la nueva campaña gana como **línea reproducible activa**.

Eso permite separar correctamente los roles:

- **Agent7250**: benchmark oficial estable;
- **Agent1850**: mejor residual histórico single-run;
- campaña stop-band confirmada: nueva línea residual activa para continuar.

Por qué este resultado sí cambia el punto operativo

La diferencia entre discovery y confirmation no es solo numérica; es metodológica. Discovery todavía estaba en modo hipótesis. Confirmation, en cambio, cumplió simultáneamente las condiciones que el propio proyecto se impuso para promover una línea:

1. al menos 3/5 seeds en **ConditionA** o **ConditionB**;
2. media agregada aceptada frente al benchmark;
3. **actionL2** media menor que **Agent7250**;
4. **saturationFraction** media menor que **Agent7250**.

Esto tiene una consecuencia práctica clara. A partir de esta fase, el proyecto deja de privilegiar corridas largas ciegas y pasa a privilegiar:

- una base congelada fuerte;
- residual learning controlado;
- checkpoints densos;
- auditoría de trayectoria completa;
- selección temprana dentro de una banda validada.

No es solo una preferencia de estilo experimental. Es una regla de operación mejor alineada con lo que este proyecto ya vio en sus corridas largas y con la forma en que la línea residual realmente se comportó al extenderla demasiado.

Punto actual del proyecto

El estado recomendado del proyecto queda fijado así:

- **benchmark oficial:** Agent7250;
- **línea residual activa: stop-band confirmada** alrededor del episodio 2000, con ventana [1750, 2250];
- **mejor residual reproducible previo:** seed 22, ahora desplazado como referencia secundaria;
- **mejor residual histórico single-run:** Agent1850.

Operativamente, esto significa que ya no conviene seguir con corridas largas abiertas como estrategia principal. La recomendación para continuar es:

1. seguir usando Agent7250 como base congelada;
2. entrenar residual con checkpoints densos;
3. auditar toda la trayectoria y no solo la cola;
4. priorizar checkpoints dentro de la ventana [1750, 2250];
5. elegir el checkpoint aceptado más temprano dentro de esa banda;
6. usar esta ventana confirmada como plataforma para barridos finos o nuevas variantes.

Veredicto final

La fase stop-band residual fue exitosa.

No cambió el benchmark oficial del proyecto, pero sí cambió de forma clara la estrategia correcta para continuar. El valor principal de esta fase no es haber encontrado “más episodios”, sino haber demostrado que la parte útil de la trayectoria residual aparece **antes** de la deriva tardía y que esa zona puede validarse de forma reproducible con seeds nuevas.

La fase stop-band convierte una intuición previa del proyecto en una regla experimental explícita y defendible. La línea vigente antes de la intervención ya mostraba que el residual era la vía correcta; las corridas largas demostraron que empujar la trayectoria demasiado lejos no era la forma correcta de explotarlo; y la campaña discovery/confirmation mostró que sí existe una banda temporal estable alrededor de 2000 episodios donde el residual ofrece el mejor compromiso operativo.

Referencias

- [1] Ziming Chen, Huasong Min, Dong Wang, Ziwei Xia, Fuchun Sun, and Bin Fang. A review of myoelectric control for prosthetic hand manipulation. *Biomimetics*, 8(3):328, 2023. doi: 10.3390/biomimetics8030328. URL <https://doi.org/10.3390/biomimetics8030328>.
- [2] Christian Done, Jaden Palmer, Kayson Oakey, Atulan Gupta, Constantine Thiros, Janet Franklin, and Marco P. Schoen. Reinforcement learning-driven prosthetic hand actuation in a virtual environment using unity ml-agents. *Virtual Worlds*, 4(4):53, 2025. doi: 10.3390/virtualworlds4040053. URL <https://doi.org/10.3390/virtualworlds4040053>.
- [3] Scott Fujimoto, Herke van Hoof, and David Meger. Addressing function approximation error in actor-critic methods. <https://arxiv.org/abs/1802.09477>, 2018. TD3 original paper.

- [4] I Lee, Hoang-Giang Cao, Cong-Tinh Dao, Yu-Cheng Chen, and I-Chen Wu. Gradient-based regularization for action smoothness in robotic control with reinforcement learning. In *Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 603–610, 2024. URL <https://arxiv.org/abs/2407.04315>.
- [5] Evgenii Nikishin, Max Schwarzer, Pierluca D’Oro, Pierre-Luc Bacon, and Aaron Courville. The primacy bias in deep reinforcement learning. In *Proceedings of the 39th International Conference on Machine Learning*, volume 162 of *Proceedings of Machine Learning Research*, pages 16828–16847. PMLR, 2022. URL <https://proceedings.mlr.press/v162/nikishin22a.html>.
- [6] Tom Silver, Kelsey Allen, Joshua B. Tenenbaum, and Leslie P. Kaelbling. Residual policy learning. <https://arxiv.org/abs/1812.06298>, 2018. Accessed: 2026-03-26.