Evolución del Control TD3 para una Prótesis Mioeléctrica

Desde la reward heredada inicial hasta el baseline válido de 8000 episodios y la extensión final a 12000

Proyecto `EMG_Prosthesis_TD3`

23 de marzo de 2026

Resumen

Este informe reordena la historia experimental completa del proyecto de control mioeléctrico con TD3, desde su formulación base hasta el baseline válido actual. El objetivo no es solo reportar el último resultado, sino explicar cómo se llegó a él y qué partes del proceso siguen siendo técnicamente valiosas. La narrativa parte del artículo base del proyecto, que planteó una observación de 44 dimensiones, un espacio de acción continuo de cuatro motores y una reward multicomponente orientada a seguimiento proporcional [Fuertes Bustos et al., 2026]. A partir de la auditoría del repositorio se identificaron problemas en la reward heredada, en la coherencia temporal del entorno y, posteriormente, un bug crítico del simulador que inmovilizaba la prótesis. Ese hallazgo obliga a reinterpretar varias corridas intermedias como etapas de depuración y no como benchmark principal. Tras corregir el simulador y reentrenar el sistema con una formulación coherente basada en tracking MSE, regularización de acción y acción efectiva cuantizada, se obtuvo primero un baseline válido de 2000 episodios y, después, un baseline refinado a 8000 episodios. El mejor checkpoint auditado de esa corrida larga fue `Agent7250`, cuyo test de 50 simulaciones alcanzó `trackingMSE = 0.043045`, `trackingMAE = 0.160336`, `actionL2 = 0.596444`, `saturationFraction = 0.392086` y Δa L2 medio de 0.321385. Finalmente, se ejecutó una extensión a 12000 episodios para verificar si un mayor presupuesto seguía mejorando el benchmark; el mejor checkpoint de esa extensión, `Agent11900`, obtuvo `trackingMSE = 0.045189`, `trackingMAE = 0.164639`, `actionL2 = 0.649868`, `saturationFraction = 0.511786` y Δa L2 medio de 0.305285, sin superar al baseline de 8000. El documento concluye que el proyecto ya dispone de un baseline sólido y defendible en simulación, y que el resultado de 12000 episodios sugiere una meseta de rendimiento bajo la formulación actual.

1. Objetivo y alcance

Este documento tiene cuatro propósitos:

1. reconstruir la evolución técnica del proyecto desde el diseño inicial hasta el baseline actual;
2. separar con claridad qué resultados deben interpretarse como benchmark válido y cuáles deben interpretarse como etapas de depuración;
3. describir con formulación matemática y trazabilidad de código la configuración que hoy sí funciona;
4. fijar el baseline operativo actual del proyecto en simulación.

Todas las corridas descritas en este informe se realizaron en simulación, con dataset pregrabado y sin hardware activo durante entrenamiento ni test:

- `usePrerecorded = true`,

- `simMotors = true`,
- `connect_glove = false`.

2. Punto de partida: el baseline conceptual del proyecto

El punto de partida conceptual del proyecto es el manuscrito *Continuous Operation of a Myoelectric Hand Prosthesis using the TD3 Reinforcement Learning Algorithm* [Fuertes Bustos et al., 2026]. Ese trabajo es importante porque fijó tres ideas fundacionales que siguen vigentes:

1. un problema de control continuo sobre cuatro motores con TD3;
2. una observación compuesta por features EMG y realimentación de encoders;
3. la necesidad de una reward cuidadosamente moldeada para evitar estrategias no proporcionales y *reward hacking*.

En el artículo base, el estado se definió con 44 dimensiones:

$$s_t^{\text{base}} = \begin{bmatrix} \phi_t \\ \text{enc}_t \end{bmatrix} \in \mathbb{R}^{44}, \tag{1}$$

donde $\phi_t \in \mathbb{R}^{40}$ contiene cinco features por cada uno de los ocho canales EMG, y $\text{enc}_t \in \mathbb{R}^4$ representa los encoders normalizados de los cuatro motores [Fuertes Bustos et al., 2026]. El espacio de acción también se fijó desde el inicio como continuo:

$$a_t \in [-1, 1]^4, \tag{2}$$

y después se escaló a PWM mediante multiplicación por una velocidad máxima.

Ese baseline conceptual sigue siendo importante porque justificó el uso de TD3 para control continuo en una prótesis mioeléctrica, en línea con la literatura sobre control actor-critic determinista y tareas continuas de manipulación [Fujimoto et al., 2018, MathWorks, 2026a, Chen et al., 2023]. Sin embargo, el repositorio evolucionó más allá de esa formulación inicial, y gran parte del trabajo reciente se centró en limpiar la reward, hacer trazable el entorno y corregir problemas estructurales que el manuscrito no capturaba todavía.

3. Evolución técnica del repositorio hasta el baseline actual

3.1. Reward heredada y primeros problemas detectados

La reward heredada del repositorio provenía de una lógica pensada para premiar dirección correcta, castigar movimiento inverso e incentivar que el agente no se quedara quieto. Su estructura efectiva podía resumirse como:

$$r_t^{\text{legacy}} = \frac{1}{4} \sum_{i=1}^{4} \left[\rho(a_{t,i}, c_{t,i}) 2 \cdot \mathbf{1}(\exists j : a_{t,j} \neq 0) - k \left| p_{t,i} - y_{t,i} \right| - \alpha \left| a_{t,i} - a_{t-1,i} \right| \right], \tag{3}$$

donde $c_{t,i}$ representaba la dirección "correcta" inferida por comparación entre posiciones consecutivas, $p_{t,i}$ la posición actual del motor y $y_{t,i}$ la referencia.

La auditoría del código encontró cuatro debilidades técnicas graves en esta formulación:

- la reward comparaba acciones como si fueran discretas, aunque TD3 generaba acciones continuas;
- existía memoria oculta entre episodios mediante variables persistentes;

- la reward se calculaba con incoherencia temporal dentro de `step`;
- la escala final de la reward no quedaba alineada de forma clara con el objetivo físico de tracking.

Estas observaciones son consistentes con la literatura de *reward shaping*: una reward puede maximizarse sin inducir necesariamente el comportamiento deseado si sus términos están mal escalados o no reflejan el objetivo real [Deng et al., 2025]. En el proyecto, eso se manifestaba en estrategias agresivas, poco proporcionales y muy sensibles a detalles de implementación.

3.2. Transición a tracking MSE y reward interpretable

La primera gran mejora estructural consistió en reemplazar la reward heredada por una reward explícita basada en error de tracking MSE normalizado y penalización de magnitud de acción. La formulación intermedia quedó:

$$r_t^{\mathrm{MSE}} = -\frac{1}{4}\sum_{i=1}^{4}\left(e_{t,i}^2 \lambda_a \tilde{a}_{t,i}^2\right), \tag{4}$$

con:

$$e_{t,i} = \hat{y}_{t,i} - y_{t,i}, \tag{5}$$

donde $\hat{y}_{t,i}$ es la flexión estimada de la prótesis en la escala del glove y $\tilde{a}_{t,i}$ es la acción efectiva normalizada.

La decisión de usar MSE fue coherente con dos criterios:

- penaliza con más fuerza errores grandes, lo que es deseable en tracking continuo;
- proporciona una señal densa y estable para TD3, a diferencia de rewards más discretas o ambiguas [Fujimoto et al., 2018, MathWorks, 2026b].

En esta etapa también se corrigieron la evaluación doble de reward dentro de `step` y el *logging* por episodio, incorporando variables como `trackingMse`, `trackingMae`, `actionL2`, PWM aplicado y, más adelante, variación de acción.

3.3. Remapeo a acción efectiva y cuantización explícita

La siguiente mejora importante consistió en alinear la acción aprendida por TD3 con la acción realmente aplicable por el simulador. El actor seguía produciendo:

$$a_t \in [-1, 1]^4, \tag{6}$$

pero esa acción se remapeaba a un conjunto discreto de PWM efectivos:

$$\mathcal{U}_{\mathrm{PWM}} = \{0, 64, 96, 128, 160, 192, 224, 255\}. \tag{7}$$

Esta intervención fue necesaria porque el simulador cuantizaba la acción de hecho, y si el entorno no hacía explícita esa cuantización, el agente podía aprender acciones pequeñas que matemáticamente parecían correctas pero físicamente eran casi nulas. Esa alineación entre acción continua y actuación efectiva es relevante en tareas protésicas y de manipulación continua [Done et al., 2025, Deng et al., 2025].

3.4. Ramas diagnósticas: progreso, 52D, 132D y TD3 recurrente

Entre la transición inicial a MSE y el baseline final se exploraron varias ramas:

- reward con término de progreso y suavidad;
- observación Markoviana ampliada a 52D con delta de encoder y acción previa;
- apilado temporal de EMG hasta 132D;
- TD3 recurrente con LSTM.

Estas ramas siguen siendo valiosas como ingeniería exploratoria porque ayudaron a entender el papel de la memoria, de la acción previa y de la suavidad. También están bien motivadas por la literatura: la regularización de suavidad puede ayudar en control robótico [Lee et al., 2024]; y el contexto temporal es relevante en control mioeléctrico [Chen et al., 2023]. Sin embargo, estas comparativas no deben tomarse como benchmark principal, porque ocurrieron antes de corregir el bug crítico del simulador. Por tanto, hoy se interpretan como una línea de aprendizaje del equipo y no como evidencia definitiva sobre la mejor arquitectura.

4. Hallazgo crítico: el simulador estaba inmóvil

El punto de inflexión real del proyecto fue el hallazgo de un bug estructural en el simulador. La auditoría mostró dos problemas:

1. la dinámica basada en `fit_C2.mat` se apoyaba en series `ws` vacías, por lo que la prótesis quedaba inmóvil aunque el agente enviara acción;
2. dentro de `step`, el tiempo del episodio se actualizaba después de leer la prótesis, introduciendo un desfase temporal de un paso.

Estas dos fallas explican por qué varias corridas previas mostraban políticas visualmente extrañas o poco conclusivas: el agente estaba optimizando rewards y señales internas del entorno, pero no estaba controlando una dinámica física efectiva.

Se aplicaron dos correcciones mínimas y de bajo riesgo:

- en el simulador de la prótesis, cuando `ws` está vacío se usa `pattern_curve.mat` como respaldo dinámico;
- en `@Env/step.m`, el tiempo del episodio se adelanta antes de leer la prótesis.

Este hallazgo obliga a una decisión metodológica importante: las corridas pre-fix no deben usarse como benchmark numérico principal. Sí deben conservarse como parte de la historia del proyecto, porque gracias a ellas se limpiaron reward, entorno, logging y pipeline. Pero el baseline operativo actual solo puede construirse a partir de corridas post-fix.

5. Formulación válida actual del problema

5.1. Observación actual

La formulación válida actual usa una observación Markoviana de 52 dimensiones:

$$s_t = \begin{bmatrix} \phi_t \\ \mathrm{enc}_t \\ \Delta\mathrm{enc}_t \\ \tilde{a}_{t-1} \end{bmatrix} \in \mathbb{R}^{52}, \tag{8}$$

donde:

- $\phi_t \in \mathbb{R}^{40}$ son las features EMG del instante actual;
- $\mathrm{enc}_t \in \mathbb{R}^4$ son los encoders normalizados;
- $\Delta\mathrm{enc}_t \in \mathbb{R}^4$ es el cambio de encoder entre pasos;
- $\tilde{a}_{t-1} \in [-1, 1]^4$ es la acción efectiva previa.

Esta formulación extiende el estado de 44D del artículo base [Fuertes Bustos et al., 2026] sin incorporar la referencia del glove como observación, lo cual preserva una interpretación correcta del problema: el agente debe inferir el control a partir de EMG y estado mecánico, no a partir del error ya calculado.

5.2. Reward actual

La reward actual es:

$$r_t = -\frac{1}{4}\sum_{i=1}^{4}\left(e_{t,i}^2 + \lambda_a \tilde{a}_{t,i}^2 + \lambda_{\Delta a}\left(\tilde{a}_{t,i} - \tilde{a}_{t-1,i}\right)^2\right), \tag{9}$$

con:

$$e_{t,i} = \hat{y}_{t,i} - y_{t,i}, \tag{10}$$

$\lambda_a = 0.01$ y $\lambda_{\Delta a} = 0.05$.

Esta reward representa la versión madura de la línea iniciada con MSE:

- el término dominante sigue siendo tracking MSE;
- la magnitud de acción evita soluciones de energía arbitraria;
- la penalización de Δa favorece suavidad de control.

El diseño es coherente con el uso de TD3 en control continuo [Fujimoto et al., 2018, MathWorks, 2026a], con literatura de *reward shaping* en manipulación [Deng et al., 2025] y con trabajos recientes de regularización de suavidad [Lee et al., 2024].

5.3. TD3 e hiperparámetros del baseline actual

La configuración vigente del baseline se resume en la Tabla 1. Esta configuración se mantuvo constante a lo largo de la corrida larga de 8000 episodios; no se mezclaron cambios adicionales de arquitectura ni de reward durante ese refinamiento.

Cuadro 1: Configuración TD3 del baseline válido refinado

Parámetro	**Valor**	**Interpretación**
Observation variant	markov52	Estado actual con contexto motor mínimo explícito
State length	52	40 features EMG + 4 encoders + 4 deltas + 4 acciones previas
Reward type	`trackingMseActionRateReward`	Tracking MSE + penalización de acción y de cambio de acción
Reward action weight	0.01	Penaliza energía excesiva
Reward delta-action weight	0.05	Penaliza cambios bruscos
Actor / critics	MLP	Arquitectura simple y estable tras la corrección del entorno
Hidden units	64	Capacidad media, suficiente para el problema actual
Actor learning rate	10^{-4}	Conservador para la política
Critic learning rate	10^{-3}	Mayor para estimación de valor
Discount factor γ	0.95	Horizonte efectivo coherente con episodios cortos
Target smooth factor τ	0.005	Actualización lenta de redes objetivo
Mini-batch size	64	Compromiso entre estabilidad y eficiencia
Replay buffer	10^5	Suficiente para la escala actual
Exploration std	0.2	Exploración moderada
Target policy std	0.2	*Policy smoothing* en TD3
Checkpoint frequency	250	Resolución suficiente para una corrida larga de 8000 episodios

6. Baseline válido inicial post-fix: la corrida de 2000 episodios

Después de corregir el simulador, la primera evidencia válida apareció con la corrida de 2000 episodios. Esa corrida no es ya el baseline final, pero sigue siendo importante porque demostró que el sistema, con el entorno corregido, sí podía aprender tracking real. Sus resultados de test de 50 simulaciones fueron:

- `trackingMSE = 0.052805`,
- `trackingMAE = 0.179093`,
- `actionL2 = 0.674957`,
- `saturationFraction = 0.474999`,
- Δa L2 medio $= 0.633264$.

Ese resultado fue el primer benchmark defendible del proyecto. Su importancia histórica no es menor: marca el punto en el que el proyecto deja de estudiar artefactos del entorno y empieza a estudiar un problema genuino de control.

7. Refinamiento del baseline: corrida de 8000 episodios

7.1. Resumen de entrenamiento

La corrida larga de refinamiento se ejecutó en la carpeta `26-03-22 10 5 40`. La Figura 1 muestra la evolución de `EpisodeReward`, `AverageReward` y `EpisodeQ0`. A diferencia de la corrida

inicial de 2000 episodios, la mejora continuó apareciendo en la parte tardía del entrenamiento, lo que justificó el aumento de presupuesto.

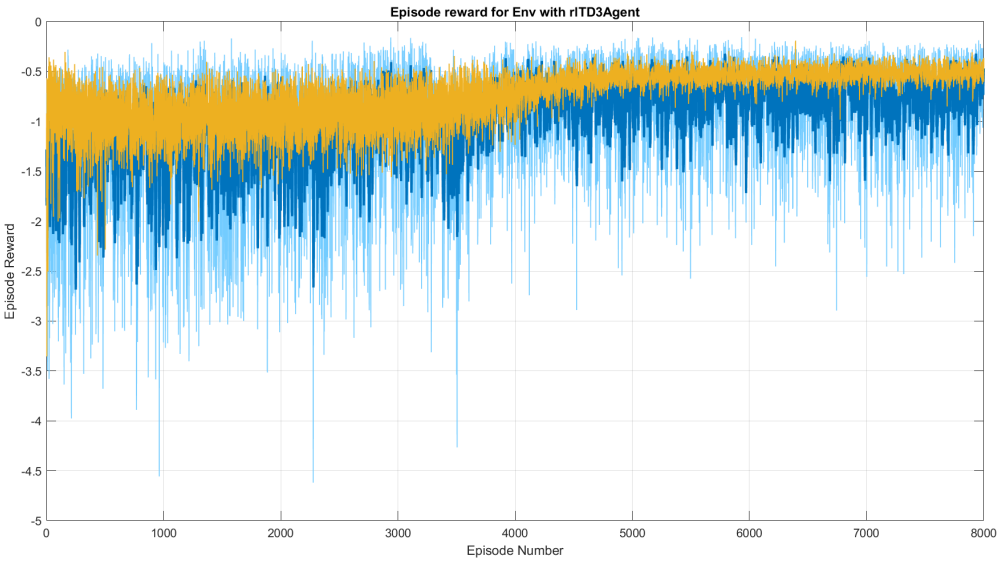

Figura 1: Corrida larga válida de 8000 episodios. La mejora del promedio móvil continúa hasta la zona del episodio 7934, lo que indica que el agente seguía refinando el control.

El resumen cuantitativo de la corrida completa se presenta en la Tabla 2.

Cuadro 2: Resumen cuantitativo de la corrida larga válida de 8000 episodios

Métrica	**Valor**	**Lectura**
EpisodeReward medio	-0.9779	Mejor que el baseline válido inicial de 2000 episodios
EpisodeReward final	-0.4860	El final de la corrida sigue siendo competitivo
Best EpisodeReward	-0.1554 en ep. 5934	Persisten episodios muy buenos también en la parte media-tardía
AverageReward final	-0.4687	El promedio final mejora de forma clara sobre el baseline de 2000 episodios
Best AverageReward	-0.3195 en ep. 7934	El mejor tramo aparece casi al final de la corrida
TrackingMSE medio	0.0612	Error de entrenamiento bajo y estable
TrackingMAE medio	0.1914	Error absoluto consistente con la mejora sostenida
ActionL2 medio	0.4672	Menor esfuerzo medio que en el baseline inicial válido
Saturation fraction	0.1992	La saturación en entrenamiento cae de forma importante
Δa L2 medio	0.1811	La política se suaviza durante el entrenamiento

La lectura técnica de esta tabla es importante: la corrida de 8000 no solo mejoró reward, sino también suavidad y saturación media durante entrenamiento. Eso sugiere una mejora real de la política y no simplemente una versión más agresiva del agente anterior.

7.2. Auditoría de checkpoints de la cola

Aunque el mejor promedio apareció cerca del episodio 7934, no se asumió que `Agent8000` fuera el mejor checkpoint. Se auditó la cola de la corrida con una evaluación rápida de 20 simulaciones por checkpoint. Los resultados se muestran en la Tabla 3.

Cuadro 3: Auditoría rápida de checkpoints de la parte final de la corrida de 8000 episodios

Checkpoint	**MSE**	**MAE**	**ActionL2**	**Sat.**	Δa	**Lectura**
Agent5750	0.046003	0.166895	**0.502443**	**0.294033**	0.333084	Muy conservador, tracking competitivo
Agent6000	0.044541	0.164541	0.569580	0.358387	0.346737	Mejora tracking, algo más agresivo
Agent7250	**0.043045**	**0.160336**	0.596444	0.392086	0.321385	Mejor tracking de la cola auditada
Agent7500	0.044390	0.163515	0.561740	0.333164	0.338822	Similar a 6000, ligeramente inferior a 7250
Agent7750	0.043835	0.162426	0.595294	0.365436	0.336460	Muy competitivo, apenas por debajo de 7250
Agent8000	0.044311	0.162612	0.530379	0.318648	**0.298875**	Final muy estable, pero no el mejor en tracking

La decisión de fijar `Agent7250` como mejor checkpoint es técnicamente razonable por dos motivos:

- obtuvo el menor `trackingMSE` de la cola auditada;
- no fue el más agresivo de los candidatos cercanos, por lo que el mejor tracking no se consiguió simplemente empujando a máxima saturación.

7.3. Test final de 50 simulaciones con `Agent7250`

El test final se ejecutó con `Agent7250`. La Figura 2 muestra el episodio 49, que es representativo del comportamiento observado.

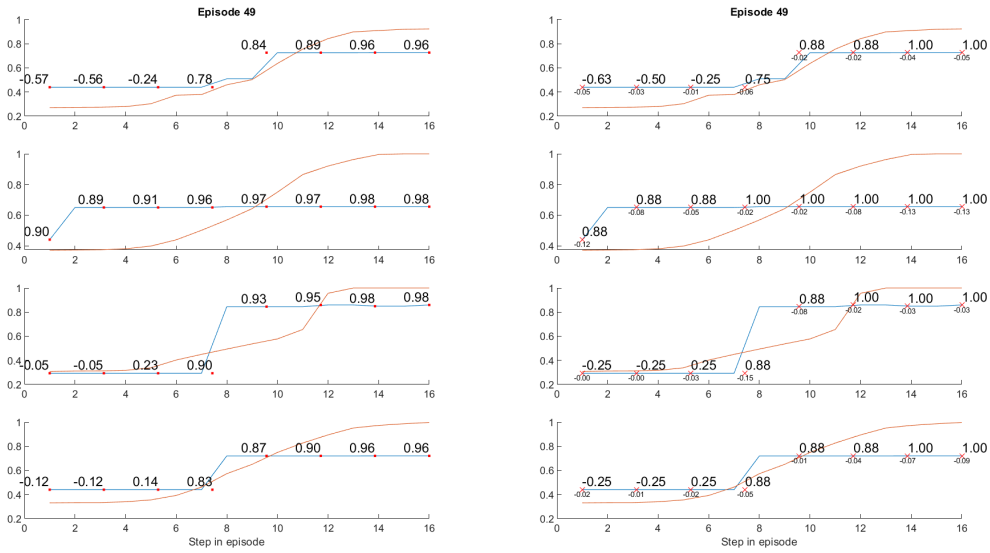

Figura 2: Episodio 49 del test final con `Agent7250`. La trayectoria azul acompaña la referencia naranja con mayor fidelidad que el baseline válido inicial, y lo hace con menor saturación global.

Las métricas agregadas del test se muestran en la Tabla 4.

Cuadro 4: Resumen del test final de 50 simulaciones con `Agent7250`

Métrica	**Valor**	**Interpretación**
TrackingMSE medio	0.043045	Nuevo mejor tracking válido del proyecto en simulación
TrackingMAE medio	0.160336	Error absoluto medio claramente mejor que el baseline inicial válido
ActionL2 medio	0.596444	Menor energía de control que el baseline de 2000 episodios
PWM absoluto medio	178.288566	El agente sigue siendo activo, pero menos extremo que el baseline inicial
Fracción de saturación	0.392086	Saturación todavía importante, pero menor que antes
Δa L2 medio	0.321385	La acción es mucho más suave que en el baseline inicial

7.4. Comparación válida: 2000 episodios vs 8000 episodios

La comparación válida más importante del proyecto no es con las ramas pre-fix, sino entre el primer baseline post-fix de 2000 episodios y el baseline refinado de 8000 episodios. Esa comparación se resume en la Tabla 5.

Cuadro 5: Comparación entre el baseline válido inicial y el baseline refinado actual

Métrica	**Agent2000**	**Agent7250**	**Lectura**
TrackingMSE	0.052805	**0.043045**	Mejora aproximada del 18.5 %
TrackingMAE	0.179093	**0.160336**	Mejora aproximada del 10.5 %
ActionL2	0.674957	**0.596444**	Menor esfuerzo total
Saturation fraction	0.474999	**0.392086**	Menor saturación efectiva
Δa L2	0.633264	**0.321385**	Política mucho más suave
PWM absoluto medio	195.913207	**178.288566**	Menor uso del extremo alto del actuador

Esta es la comparación que hoy sí debe usarse para defender el estado del proyecto. Muestra que aumentar el presupuesto a 8000 episodios, manteniendo la formulación actual, no solo mejoró tracking sino también el compromiso tracking–agresividad. Esa es una conclusión mucho más fuerte que la que se tenía en el baseline inicial.

8. Extensión final del presupuesto: corrida de 12000 episodios

8.1. Motivación y resumen de entrenamiento

Después del baseline refinado de 8000 episodios se ejecutó una corrida adicional de 12000 episodios con la misma formulación válida: observación Markoviana de 52 dimensiones, reward de tracking MSE con regularización de acción y Δa, y remapeo de acción efectiva. El objetivo de esta extensión no fue cambiar la formulación, sino comprobar si un presupuesto mayor seguía generando mejoras defendibles.

La corrida se ejecutó en la carpeta `26-03-23 15 24 51`. La Figura 3 resume `EpisodeReward`, `AverageReward` y `EpisodeQ0`.

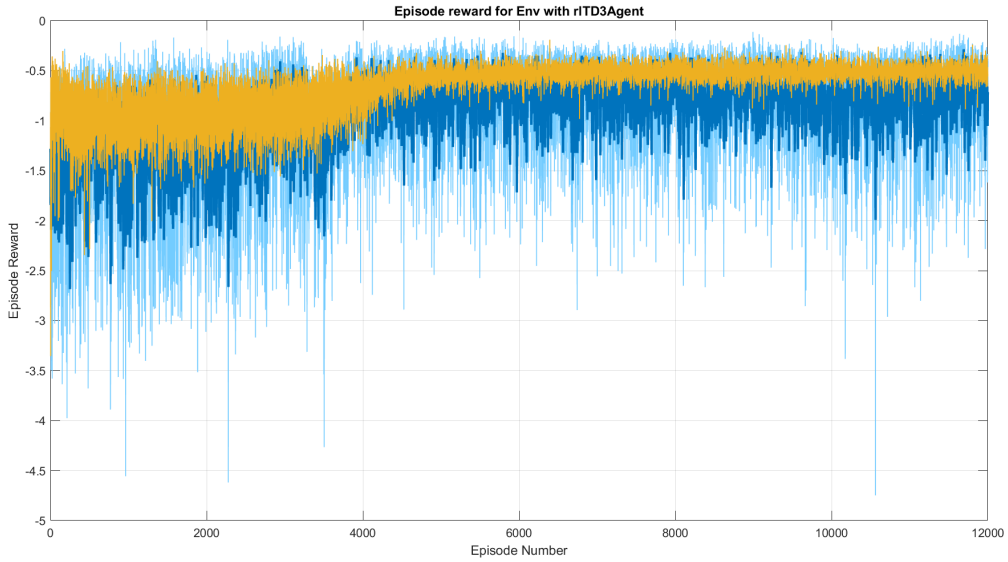

Figura 3: Extensión final de 12000 episodios. El promedio móvil sigue mejorando hasta la zona tardía del entrenamiento, con mejor promedio en el episodio 11691.

Cuadro 6: Resumen cuantitativo de la extensión a 12000 episodios

Métrica	**Valor**	**Lectura**
EpisodeReward medio	-0.909355	Mejor media global de reward que la corrida de 8000, consistente con mayor actividad de control
AverageReward final	-0.712655	El final sigue siendo competitivo, aunque no garantiza mejor test
Best AverageReward	-0.284368 en ep. 11691	El mejor tramo aparece muy cerca del final de la extensión
TrackingMSE medio	0.055620	Entrenamiento con error bajo, pero no necesariamente mejor generalización
TrackingMAE medio	0.182434	Consistente con la mejora de reward observada en entrenamiento
ActionL2 medio	0.480794	El entrenamiento usa esfuerzo moderado, todavía superior al de varias fases tempranas
Saturation fraction	0.247207	La saturación media durante entrenamiento sigue contenida
Δa L2 medio	0.203150	El control entre pasos se mantiene relativamente suave

La lectura importante es metodológica: una mejora tardía en `AverageReward` no implica automáticamente una mejora del mejor checkpoint en test. Por eso la extensión se auditó de nuevo por checkpoints.

8.2. Auditoría tardía de checkpoints

Se auditaron los checkpoints `Agent11400` a `Agent12000`. Primero se hizo una selección rápida y luego un desempate de 50 simulaciones para los candidatos finales. Los resultados agregados del desempate completo se resumen en la Tabla 7.

Cuadro 7: Auditoría de la cola de la corrida de 12000 episodios

Checkpoint	**MSE**	**MAE**	**ActionL2**	**Sat.**	Δa	**Lectura**
Agent11700	0.045719	0.166364	**0.506650**	**0.344956**	0.330661	Más conservador entre los finalistas, pero no el mejor tracking
Agent11800	0.045339	**0.164531**	0.627977	0.461101	0.308674	Muy competitivo, pero ya más agresivo
Agent11900	**0.045189**	0.164639	0.649868	0.511786	**0.305285**	Mejor MSE de la extensión, a costa de mayor saturación y esfuerzo

Con el criterio primario del proyecto, `trackingMSE`, el mejor checkpoint de la extensión fue `Agent11900`. Por eso se ejecutó el test visual final con ese agente.

8.3. Test final de 50 simulaciones con `Agent11900`

El test final de la extensión se ejecutó con `Agent11900`. La Figura 4 muestra el episodio 49.

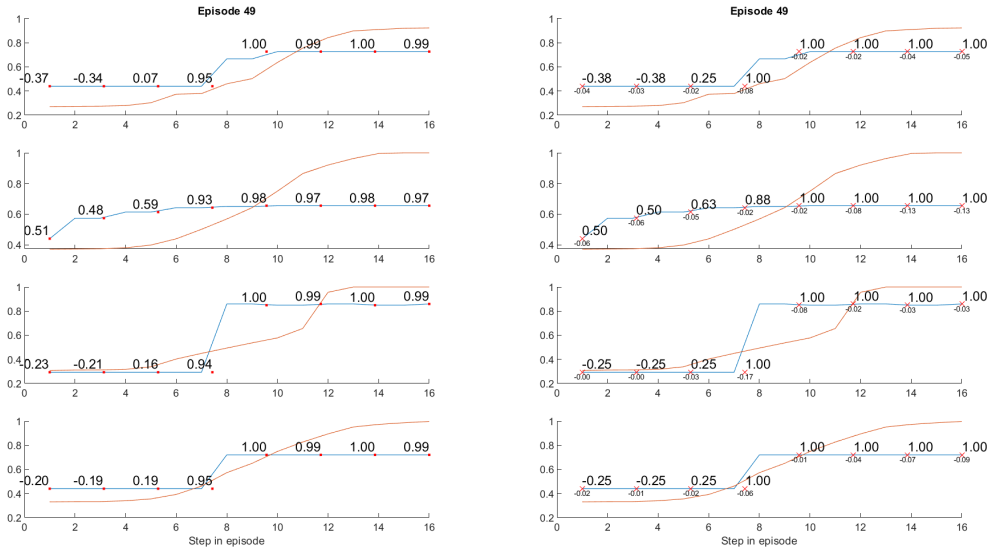

Figura 4: Episodio 49 del test final con `Agent11900`. El tracking sigue siendo bueno, pero el control aparece más agresivo que en el baseline refinado de 8000 episodios.

Cuadro 8: Resumen del test final de 50 simulaciones con `Agent11900`

Métrica	**Valor**	**Interpretación**
TrackingMSE medio	0.045189	Buen tracking, pero peor que el baseline refinado de 8000 episodios
TrackingMAE medio	0.164639	Ligeramente peor que el baseline refinado
ActionL2 medio	0.649868	Mayor esfuerzo total que el mejor agente de 8000 episodios
PWM absoluto medio	189.988960	Mayor uso del actuador que el baseline refinado
Fracción de saturación	0.511786	Aumento marcado de saturación respecto al baseline vigente
Δa L2 medio	0.305285	Leve mejora en suavidad de cambio entre acciones

8.4. Comparación válida: 8000 episodios vs 12000 episodios

La Tabla 9 muestra la comparación correcta entre el mejor checkpoint del baseline refinado de 8000 episodios y el mejor checkpoint obtenido en la extensión a 12000 episodios.

Cuadro 9: Comparación entre el baseline refinado de 8000 episodios y la extensión final de 12000 episodios

Métrica	**Agent7250**	**Agent11900**	**Lectura**
TrackingMSE	**0.043045**	0.045189	La extensión pierde tracking frente al baseline vigente
TrackingMAE	**0.160336**	0.164639	El error absoluto también empeora ligeramente
ActionL2	**0.596444**	0.649868	Mayor esfuerzo total en la extensión
Saturation fraction	**0.392086**	0.511786	La extensión satura bastante más
Δa L2	0.321385	**0.305285**	La extensión mejora un poco la suavidad local
PWM absoluto medio	**178.288566**	189.988960	Mayor uso del actuador en la extensión

La conclusión de esta comparación es clara: la extensión a 12000 episodios fue un experimento final útil, pero no produjo un nuevo mejor baseline. El `Agent11900` demuestra que el sistema sigue encontrando políticas competitivas, pero no supera el compromiso tracking–agresividad ya alcanzado por `Agent7250`. Por tanto, el baseline operativo del proyecto sigue siendo el de 8000 episodios.

9. Qué sigue siendo útil de las etapas previas

Aunque las ramas pre-fix no deban usarse como benchmark numérico principal, sí dejaron aprendizaje técnico acumulado que sigue vigente:

- la auditoría de reward fue correcta: la reward heredada debía ser sustituida por una reward explícita y densa;
- la incorporación de *logging* detallado por episodio fue crucial para detectar mejoras reales;
- el remapeo de acción efectiva fue una intervención necesaria y permanece en el baseline actual;
- las ramas de 52D, 132D y TD3 recurrente sirvieron para descartar hipótesis y entender mejor la relación entre observabilidad, memoria y suavidad.

En otras palabras, esas etapas no se pierden: pasan de ser "comparativas finales" a ser "trabajo de ingeniería que hizo posible el baseline actual".

10. Veredicto técnico actual

El estado actual del proyecto puede resumirse en cinco afirmaciones:

1. el proyecto parte de una línea base conceptualmente sólida basada en TD3, observación EMG y control continuo [Fuertes Bustos et al., 2026];
2. la reward heredada del repositorio debía ser reemplazada, y la transición a MSE fue una decisión correcta;
3. las comparativas intermedias anteriores al fix del simulador deben interpretarse como evolución técnica, no como benchmark definitivo;
4. tras corregir el simulador, el baseline de 52 dimensiones demostró que el proyecto sí podía aprender tracking real;

5. la corrida de 8000 episodios refinó ese baseline y fijó a `Agent7250` como mejor agente operativo actual;

6. la extensión final a 12000 episodios no superó ese benchmark, por lo que hoy existe evidencia de una meseta bajo la formulación actual.

Por tanto, el proyecto ya no está en una fase de "exploración incierta" sino en una fase de optimización fina sobre una base válida y ya bastante madura.

11. Línea futura recomendada

La siguiente etapa no debería volver a cambiar observación, reward y arquitectura a la vez. Ahora que existe un baseline válido y refinado, la línea de menor riesgo es:

1. conservar la observación Markoviana de 52 dimensiones;

2. mantener TD3 y el remapeo de acción efectiva;

3. estudiar ajustes finos de λ_a y $\lambda_{\Delta a}$ para reducir saturación sin perder el tracking logrado;

4. evitar, por ahora, seguir aumentando solo el presupuesto de episodios, porque la extensión a 12000 ya no mejoró el benchmark;

5. dejar arquitecturas más complejas o estrategias híbridas para una etapa posterior y ya sobre un benchmark estable.

Esta línea es coherente con la literatura. TD3 sigue siendo adecuado para control continuo [Fujimoto et al., 2018, MathWorks, 2026a]; la suavidad de acción es una propiedad deseable en robótica [Lee et al., 2024]; y en prótesis mioeléctricas la estabilidad y la interpretabilidad de la señal de control son tan importantes como el error medio puro [Chen et al., 2023, Done et al., 2025].

12. Conclusión

La conclusión correcta del proyecto ya no es que "TD3 podría servir" ni que "el reward parece razonable". La conclusión correcta es mucho más fuerte: el proyecto ha recorrido una secuencia completa de depuración, rediseño de reward, alineación de acción efectiva, detección y corrección de un bug crítico de simulación, y refinamiento experimental hasta llegar a un baseline válido y cuantitativamente mejorado.

En esa historia, el baseline conceptual del artículo inicial [Fuertes Bustos et al., 2026] fue importante porque fijó la dirección del problema. La auditoría del repositorio fue importante porque mostró que el reward original y el entorno tenían incoherencias. Las ramas intermedias fueron importantes porque enseñaron qué hipótesis no bastaban por sí solas. Pero el punto verdaderamente decisivo fue la corrección del simulador. A partir de ahí, el baseline de 2000 episodios demostró que el sistema sí aprendía. La corrida de 8000 episodios demostró que ese aprendizaje podía refinarse hasta mejorar simultáneamente tracking, esfuerzo, saturación y suavidad. La extensión final a 12000 episodios, por su parte, fue valiosa porque confirmó un límite práctico: más presupuesto por sí solo ya no está mejorando el mejor agente.

Ese es el estado actual del proyecto: no un prototipo especulativo, sino un baseline serio en simulación, con un mejor agente bien identificado (`Agent7250`) y con evidencia experimental suficiente para enfocar la siguiente fase en mejorar la agresividad del control, no en seguir aumentando episodios sin cambiar la formulación.

Referencias

Ziming Chen, Huasong Min, Dong Wang, Ziwei Xia, Fuchun Sun, and Bin Fang. A review of myoelectric control for prosthetic hand manipulation. *Biomimetics*, 8(3):328, 2023. doi: 10.3390/biomimetics8030328. URL https://doi.org/10.3390/biomimetics8030328.

Zelin Deng, Yunlong Dong, and Xing Liu. Reward shaping in reinforcement learning for robotic hand manipulation. *Neurocomputing*, 638:130204, 2025. doi: 10.1016/j.neucom.2025.130204. URL https://doi.org/10.1016/j.neucom.2025.130204.

Christian Done, Jaden Palmer, Kayson Oakey, Atulan Gupta, Constantine Thiros, Janet Franklin, and Marco P. Schoen. Reinforcement learning-driven prosthetic hand actuation in a virtual environment using unity ml-agents. *Virtual Worlds*, 4(4):53, 2025. doi: 10.3390/virtualworlds4040053. URL https://doi.org/10.3390/virtualworlds4040053.

Jose Gabriel Fuertes Bustos, Carlos Ayala, Lorena Isabel Barona, Marco E. Benalcazar, and Angel Leonardo Valdivieso. Continuous operation of a myoelectric hand prosthesis using the td3 reinforcement learning algorithm. Technical manuscript provided by the user, 2026. Baseline conceptual article used as historical reference for the project.

Scott Fujimoto, Herke van Hoof, and David Meger. Addressing function approximation error in actor-critic methods. https://arxiv.org/abs/1802.09477, 2018. TD3 original paper.

I Lee, Hoang-Giang Cao, Cong-Tinh Dao, Yu-Cheng Chen, and I-Chen Wu. Gradient-based regularization for action smoothness in robotic control with reinforcement learning. In *Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 603–610, 2024. URL https://arxiv.org/abs/2407.04315.

MathWorks. rltd3agent. https://www.mathworks.com/help/reinforcement-learning/ref/rl.agent.rltd3agent.html, 2026a. Accessed: 2026-03-12.

MathWorks. rltd3agentoptions. https://www.mathworks.com/help/reinforcement-learning/ref/rl.option.rltd3agentoptions.html, 2026b. Accessed: 2026-03-12.